CONTENT LIST

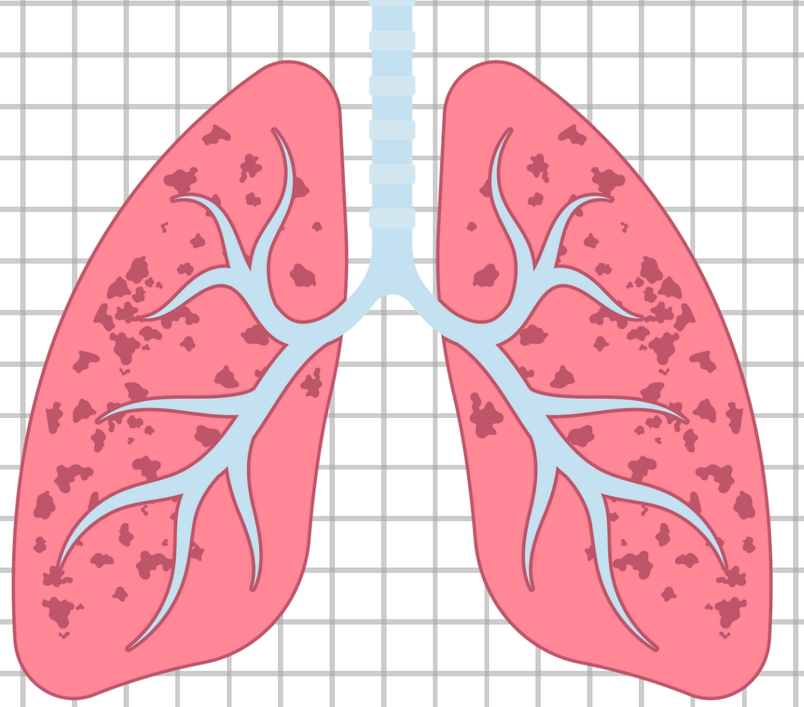
1 Pendahuluan

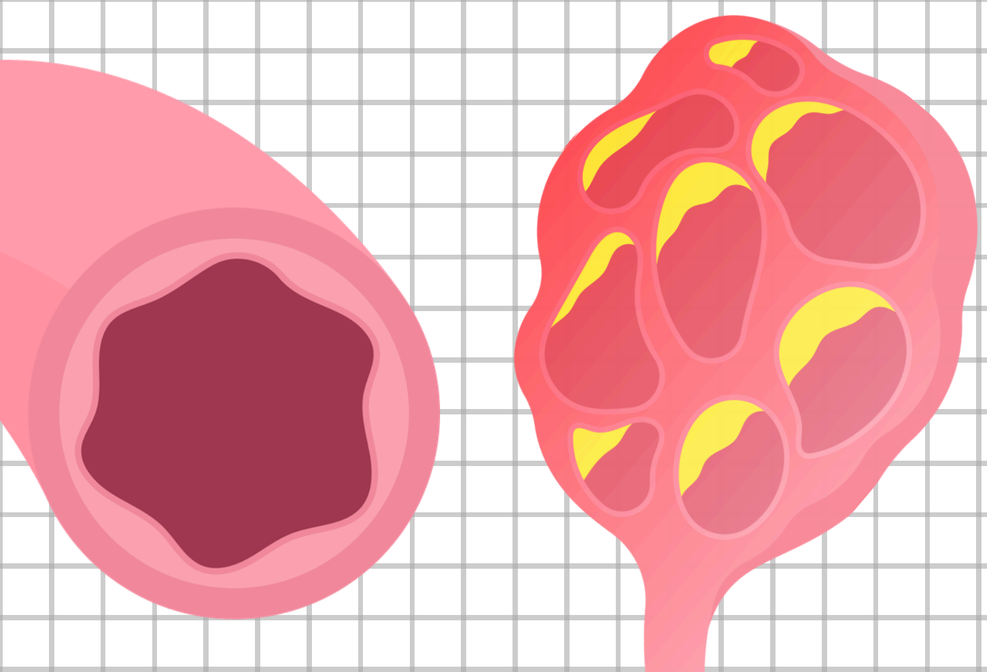
2 Kajian Teori

3 Metodologi Penelitian

4 Pembahasan

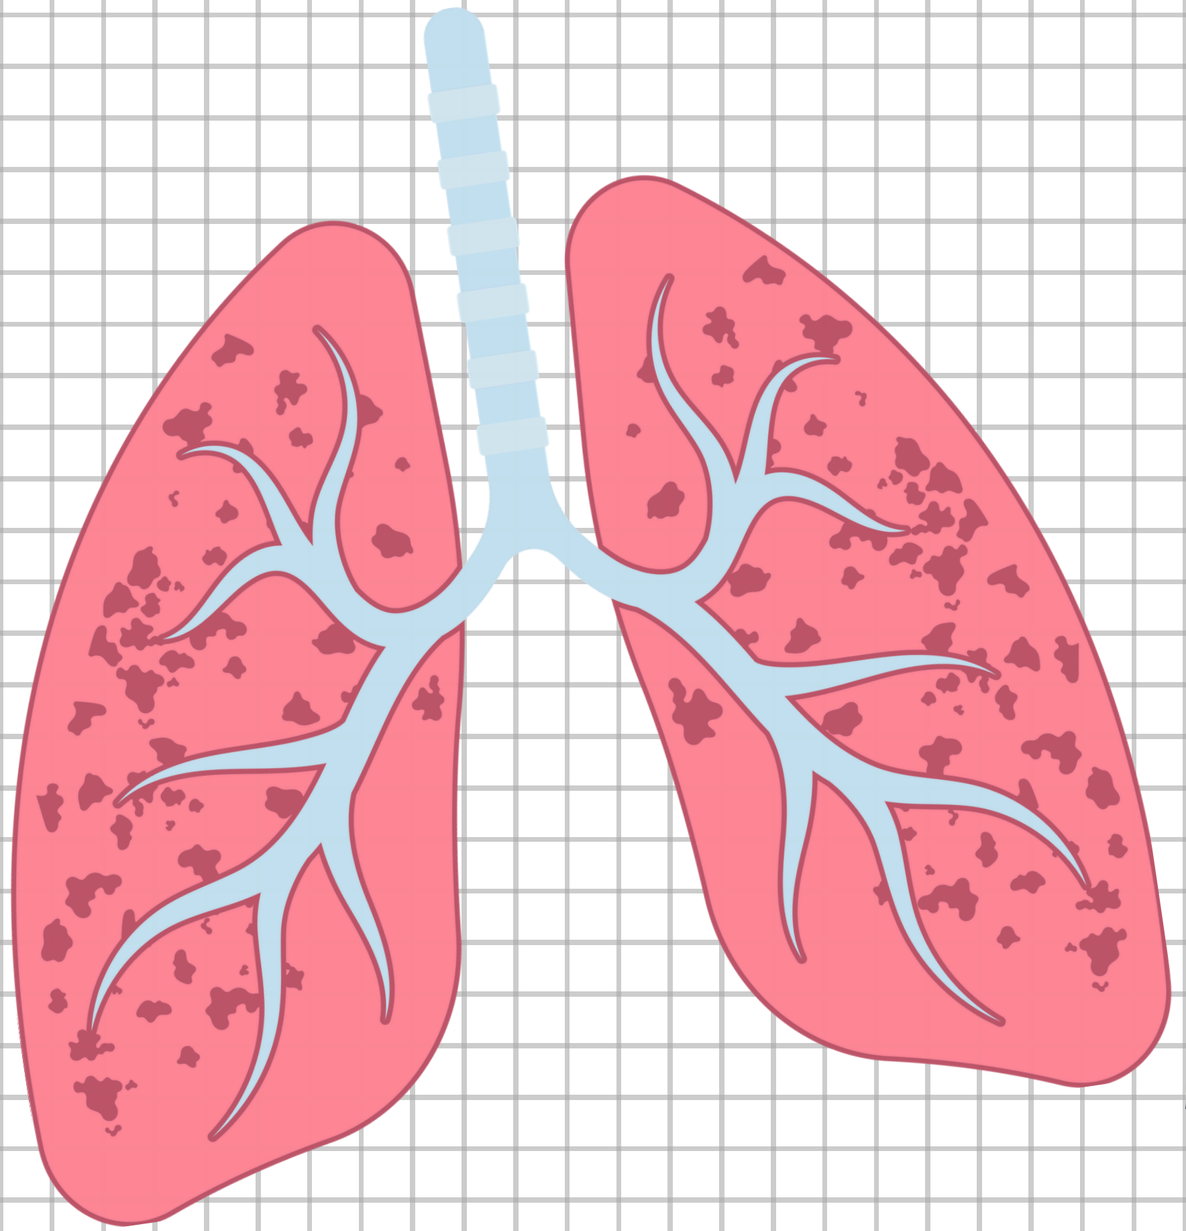
5 Kesimpulan





BAB 1

Pendahuluan



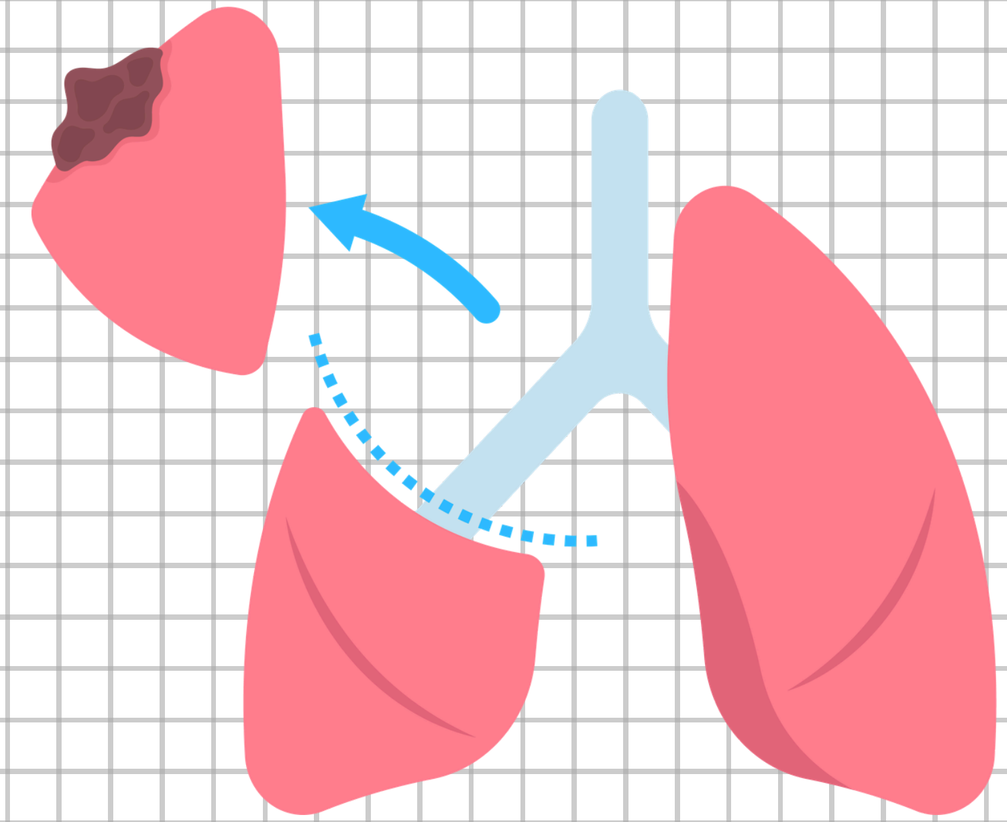
LATAR BELAKANG

Kanker paru-paru merupakan salah satu penyakit dengan tingkat kematian tertinggi di dunia. Penelitian ini berfokus pada pemanfaatan machine learning dalam memprediksi tingkat keparahan kanker paru-paru berdasarkan data pasien yang mencakup berbagai faktor klinis dan non-klinis.

URGENSI

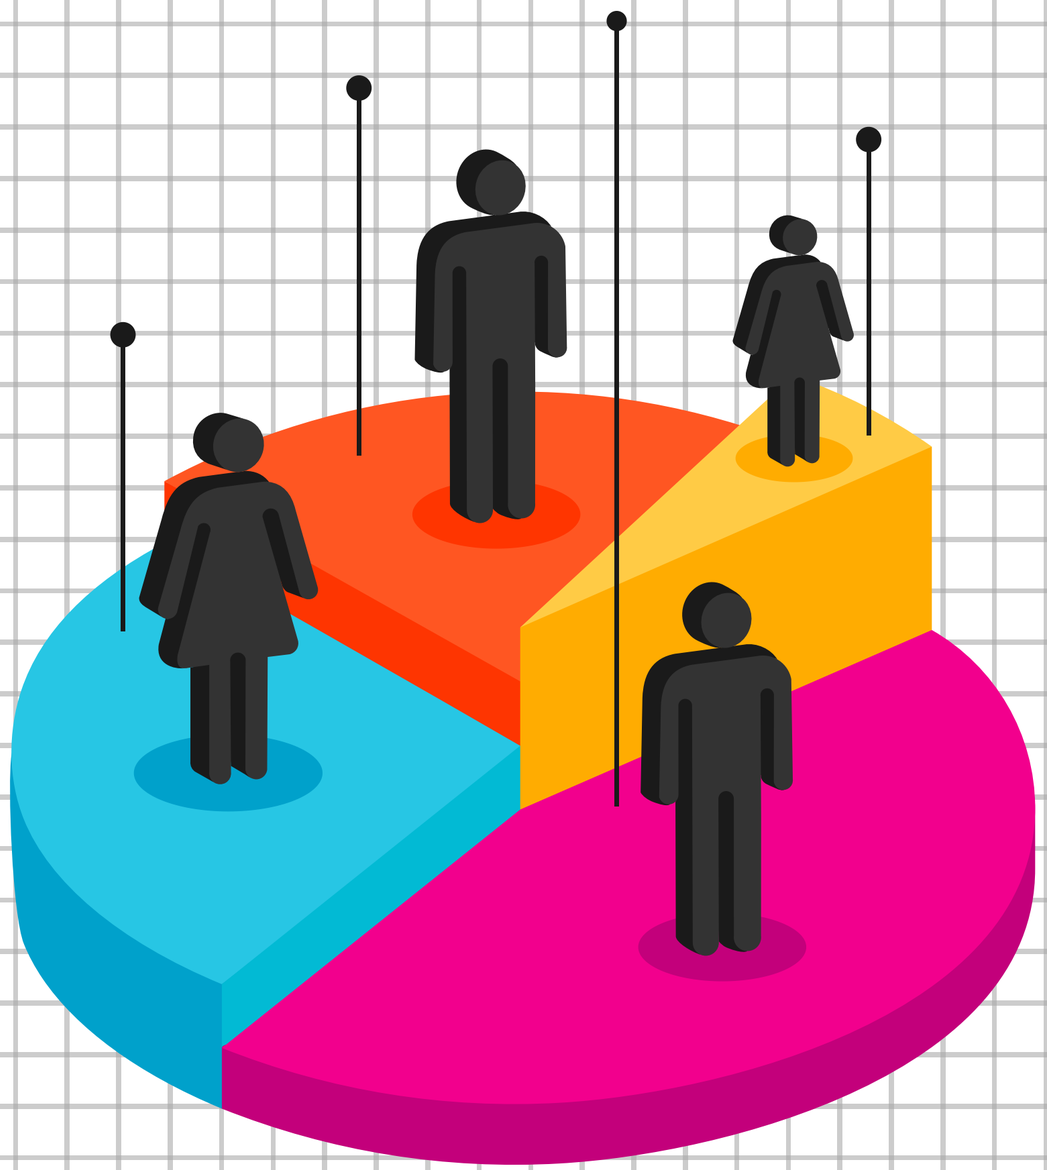
Kanker paru-paru menduduki peringkat pertama penyebab kematian akibat kanker secara global, dengan lebih dari 2,4 juta kasus baru dan 1,8 juta kematian pada tahun 2022 (GLOBACAN, 2022).

Seringkali, penyakit ini terdiagnosis dalam stadium lanjut karena gejala awalnya yang tidak khas, seperti batuk ringan atau kelelahan (WHO, 2023).



FAKTOR-FAKTOR PENGARUH TINGKAT KEPARAHAN KANKER PARU-PARU

- Demografis
- Gaya Hidup
- Lingkungan
- Genetik
- Gejala Klinis



DEMOGRAFIS

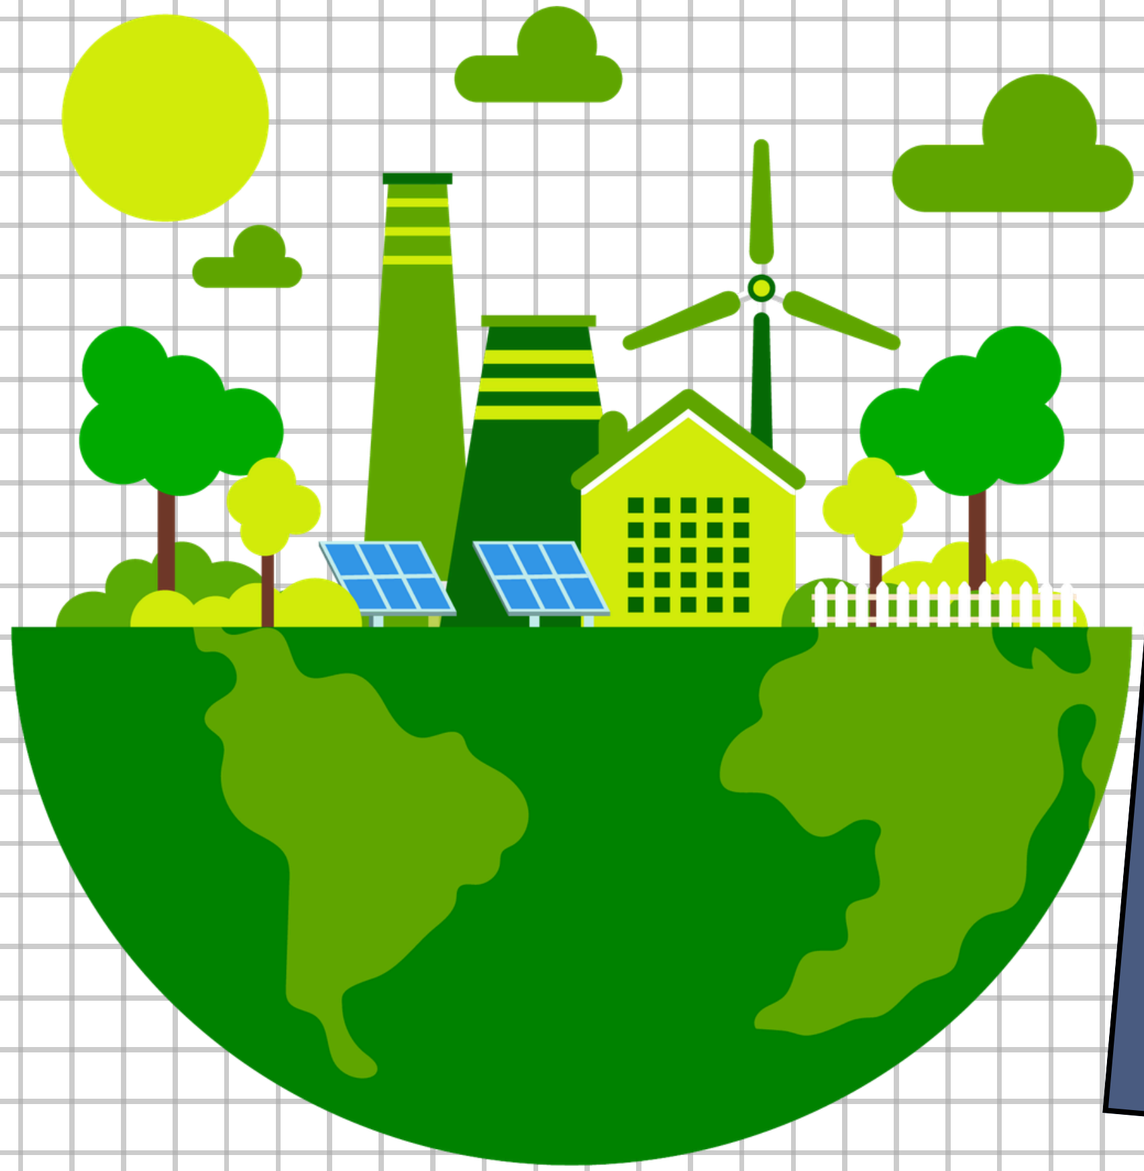
Usia lanjut dan jenis kelamin merupakan indikator penting dalam risiko kanker paru-paru. Pasien berusia tua cenderung mengalami kanker pada stadium lanjut. Meski dulu lebih banyak dialami laki-laki, kini perempuan usia 30–49 tahun mulai menunjukkan insidensi lebih tinggi, dipengaruhi oleh perubahan kebiasaan merokok dan lingkungan (Jose et al., 2023; McDowell, 2020).

HEALTHY LIFESTYLE



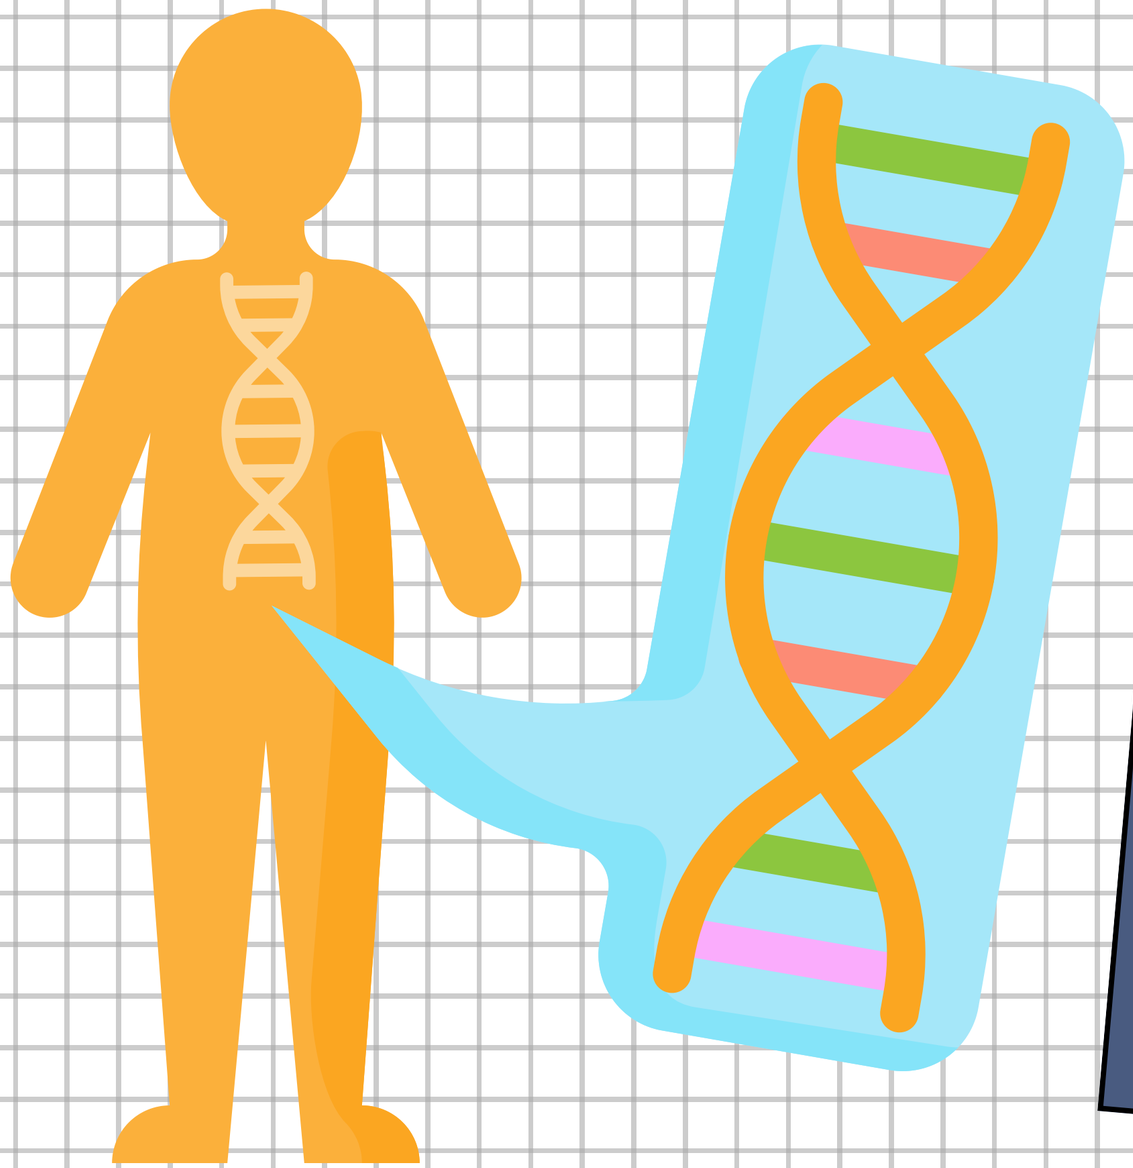
GAYA HIDUP

Kebiasaan merokok, baik dari segi durasi maupun intensitas, berhubungan langsung dengan tingkat keparahan kanker paru-paru. Selain itu, gaya hidup sehat seperti olahraga teratur dan pola makan seimbang berperan dalam pencegahan (Herlina et al., 2014; WHO, 2022).



LINGKUNGAN

Paparan polusi, asap industri, asbes, dan perokok pasif meningkatkan risiko kanker paru-paru. Perokok pasif terpapar karsinogen yang sama dengan perokok aktif. Lingkungan dengan kualitas udara buruk turut memperparah kondisi paru-paru (Du et al., 2020; WHO, 2022).



GENETIK

Riwayat keluarga dengan kanker paru-paru meningkatkan risiko individu terkena penyakit ini. Selain faktor genetik, kondisi seperti penyakit paru kronik juga mempercepat penyebaran dan keparahan kanker (Islam et al., 2015).



GEJALA KLINIS

Gejala seperti nyeri dada, batuk darah, sesak napas, dan penurunan berat badan sering kali muncul saat kanker sudah cukup parah. Deteksi dini gejala-gejala ini penting dalam menentukan tingkat keparahan dan penanganan yang tepat (WHO, 2022).

VARIABEL TARGET



Variabel

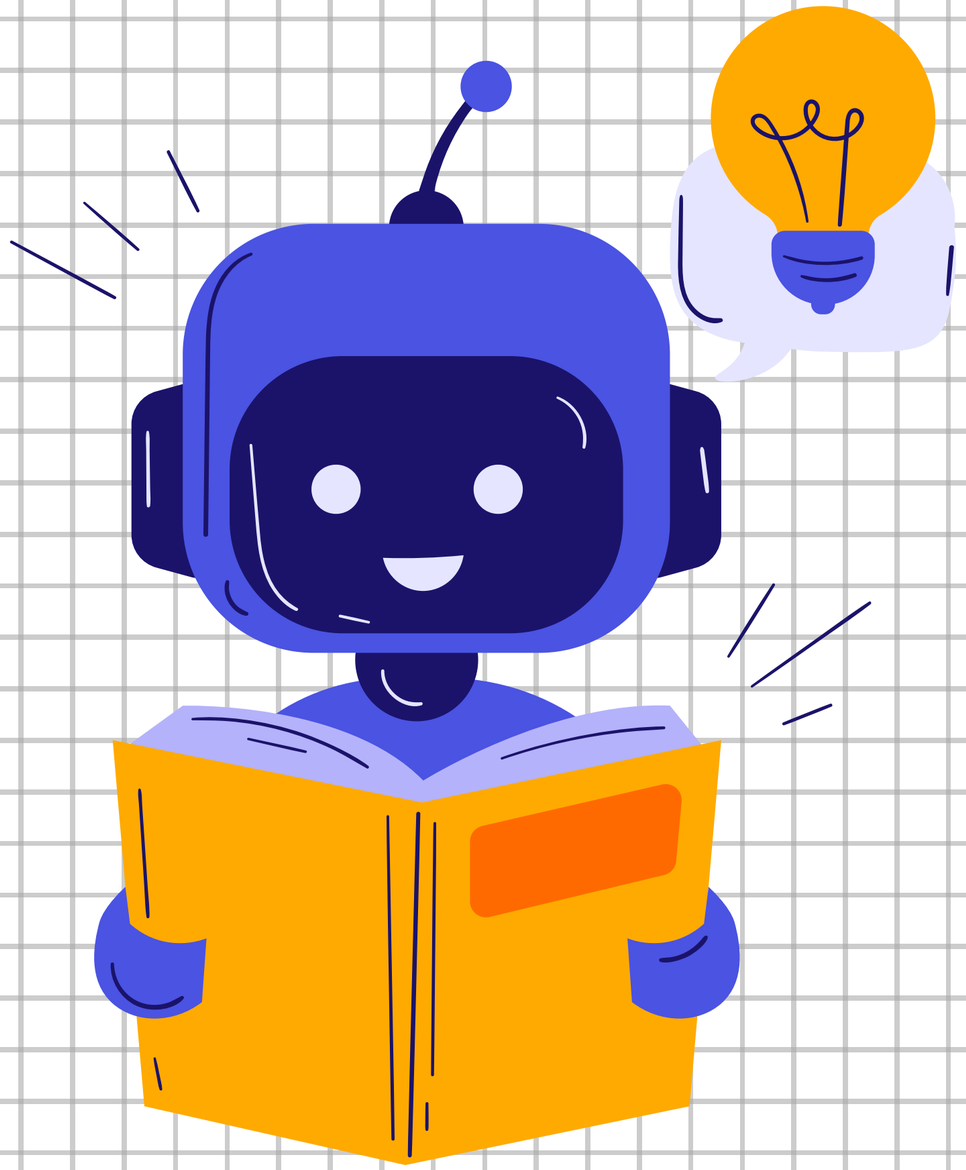
Tujuan utama model adalah memprediksi label “Level”, yaitu tingkat keparahan kanker paru-paru:
🟢 Low 🟡 Medium 🔴 High

Deskripsi

Kategori ini dibentuk berdasarkan kombinasi faktor risiko dan menjadi variabel target dalam pemodelan machine learning.

PERAN MACHINE LEARNING

Machine learning memungkinkan analisis data medis dalam jumlah besar dan kompleks secara efisien.
Teknik ini dapat mengidentifikasi pola-pola tersembunyi dalam data pasien yang tidak mudah dikenali melalui metode konvensional.



MODEL YANG DIGUNAKAN

- Logistic Regression
- K-Nearest Neighbors
- Random Forest
- SVM
- Decision Tree



RUMUSAN MASALAH

- Faktor apa saja yang berkontribusi signifikan terhadap tingkat keparahan kanker paru-paru?
- Bagaimana faktor-faktor yang berkontribusi signifikan dapat memprediksi tingkat keparahan kanker paru-paru?
- Bagaimana hubungan antara faktor gaya hidup dan lingkungan dengan tingkat keparahan kanker paru-paru?
- Bagaimana hubungan antara gejala klinis dengan tingkat keparahan kanker paru-paru?

TUJUAN

- Menganalisis faktor-faktor yang berkontribusi signifikan terhadap tingkat keparahan kanker paru-paru.
- Menganalisis sejauh mana faktor demografis, gaya hidup, lingkungan, klinis, gejala, dan genetik dapat digunakan untuk memprediksi tingkat keparahan kanker paru-paru.
- Menganalisis hubungan antara faktor gaya hidup dan lingkungan dengan tingkat keparahan kanker paru-paru.
- Menganalisis hubungan antara gejala klinis dengan tingkat keparahan kanker paru-paru.



MANFAAT

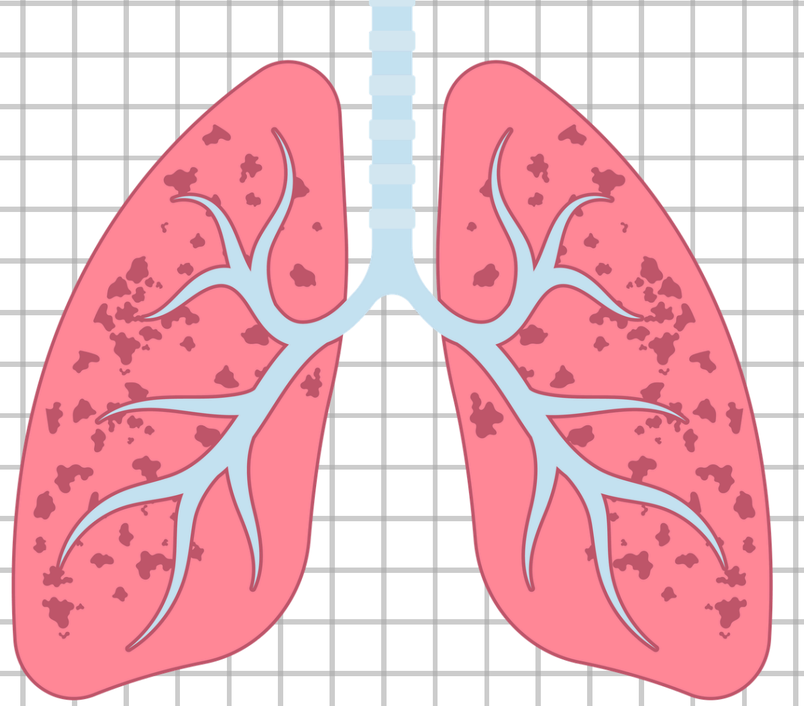
BENEFITS

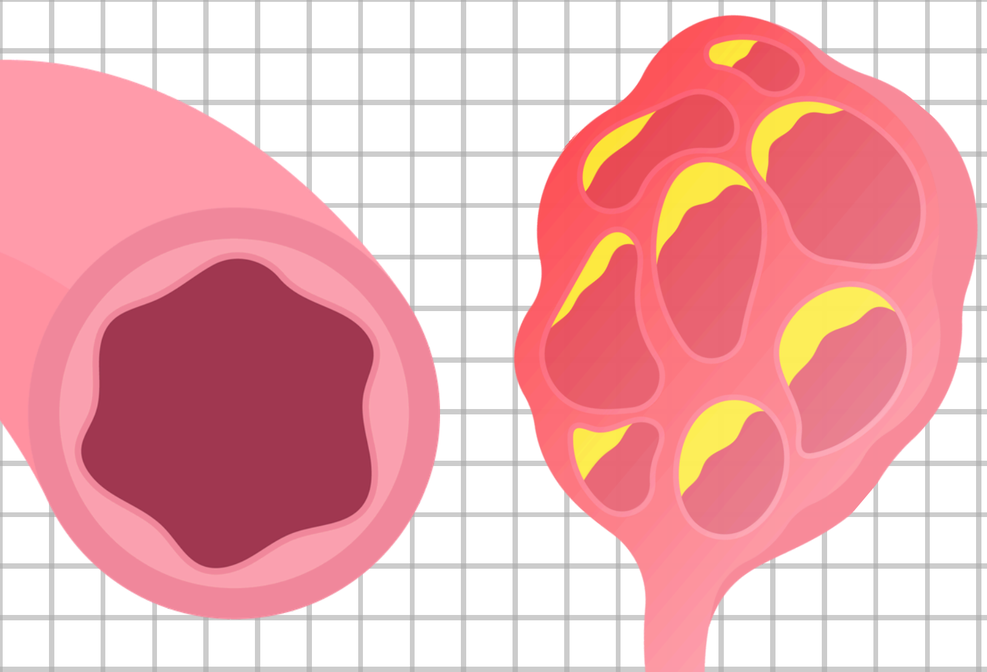
Teoritis

1. Memberikan kontribusi ilmiah dalam pengembangan model prediktif berbasis machine learning untuk tingkat keparahan kanker paru-paru, dengan mempertimbangkan faktor demografis, gaya hidup, lingkungan, gejala klinis, dan genetik.
2. Menambah wawasan ilmiah tentang faktor-faktor yang mempengaruhi tingkat keparahan kanker paru-paru.
3. Menambah pemahaman baru tentang hubungan antara faktor demografis, gaya hidup, lingkungan, gejala klinis, dan genetik dalam mempengaruhi tingkat keparahan kanker paru-paru.

Praktis

1. Membantu tenaga medis dalam melakukan klasifikasi risiko pasien kanker paru-paru secara tepat sehingga dapat menyusun strategi pengobatan dengan efektif.
2. Memberikan model keputusan klinis untuk mengidentifikasi pasien yang memerlukan pemantauan yang lebih ketat berdasarkan faktor risiko yang diprediksi model.

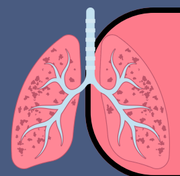




BAB 2

Kajian Teori

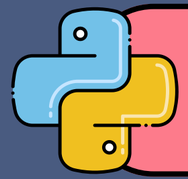
KAJIAN TEORI



Kanker Paru



Machine Learning



Python

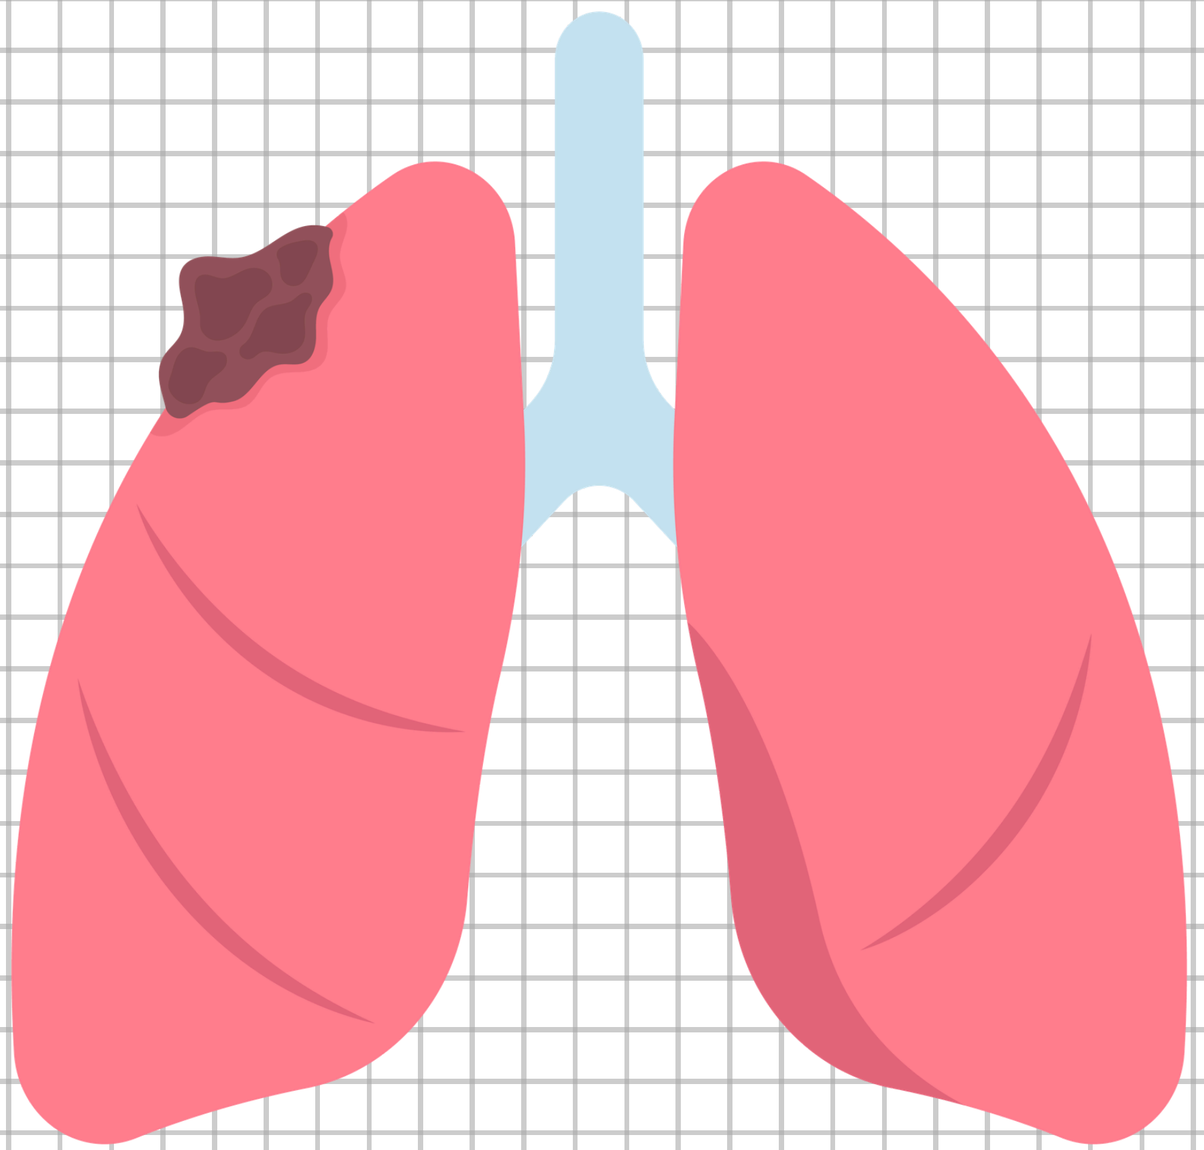


Penelitian Terkait

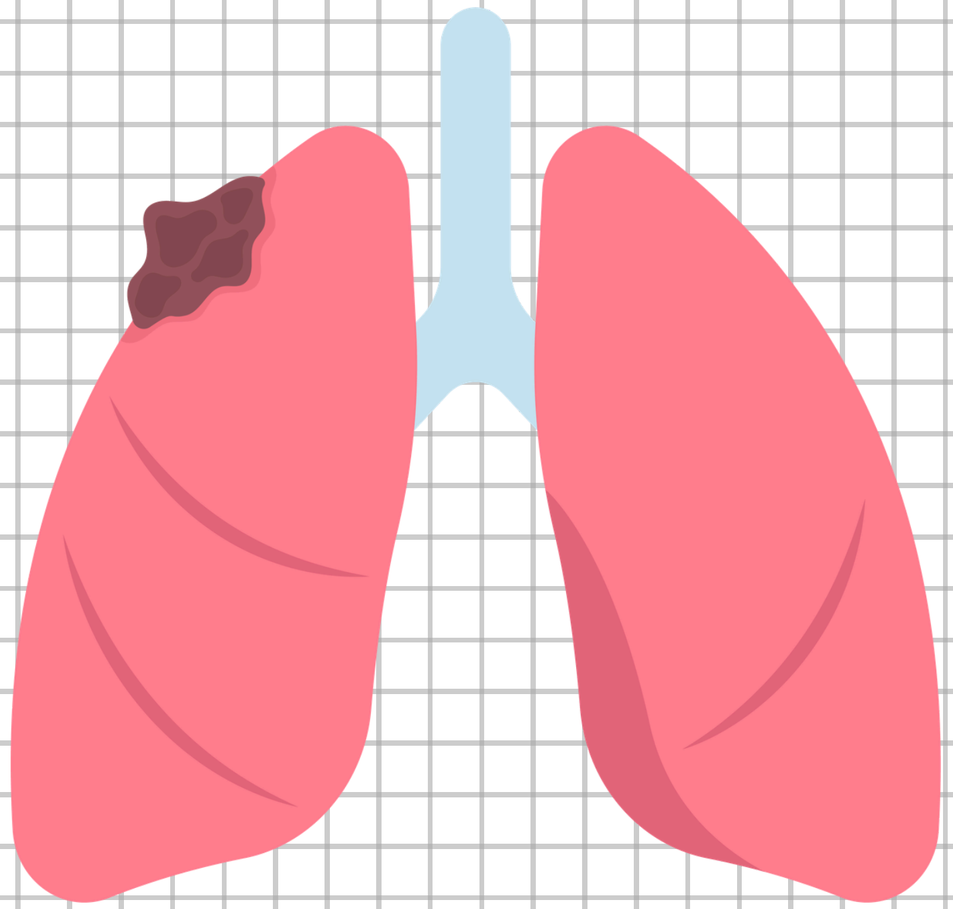
KANKER PARU

Kanker Paru

Kanker paru terjadi saat sel paru tumbuh tak terkendali membentuk tumor. Menurut (GLOBACAN (2022)), ini adalah penyebab utama kematian akibat kanker secara global



KLASIFIKASI KANKER PARU



Non-Small Cell Lung Cancer

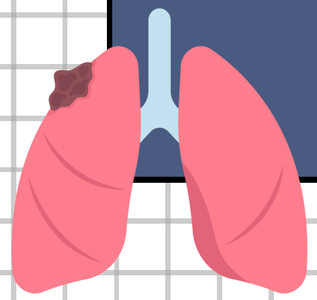
- Jenis paling umum
- Pertumbuhannya lambat
- Pragnosis lebih baik

Small Cell Lung Cancer

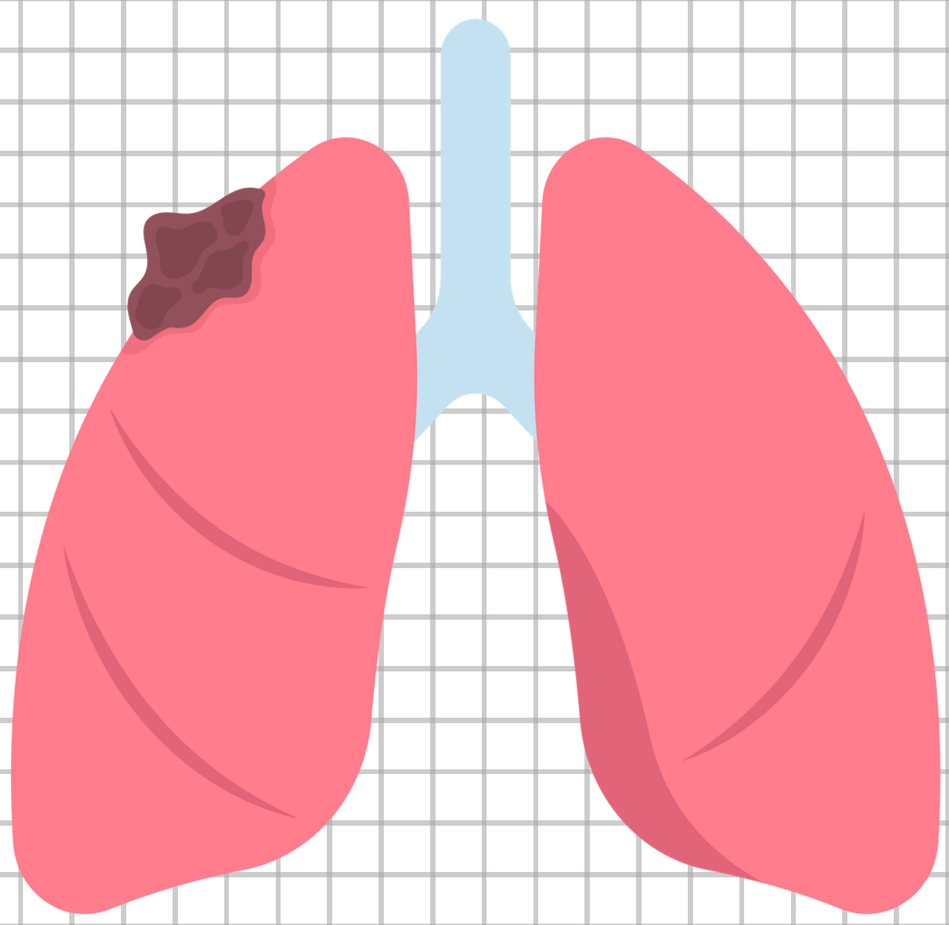
- Lebih agresif dan cepat menyebar
- Umumnya terdiagnosis di stadium lanjut

PATOGENESIS KANKER PARU

- Inisiasi
- Koversi
- Promosi
- Progresi



PATOGENESIS KANKER PARU



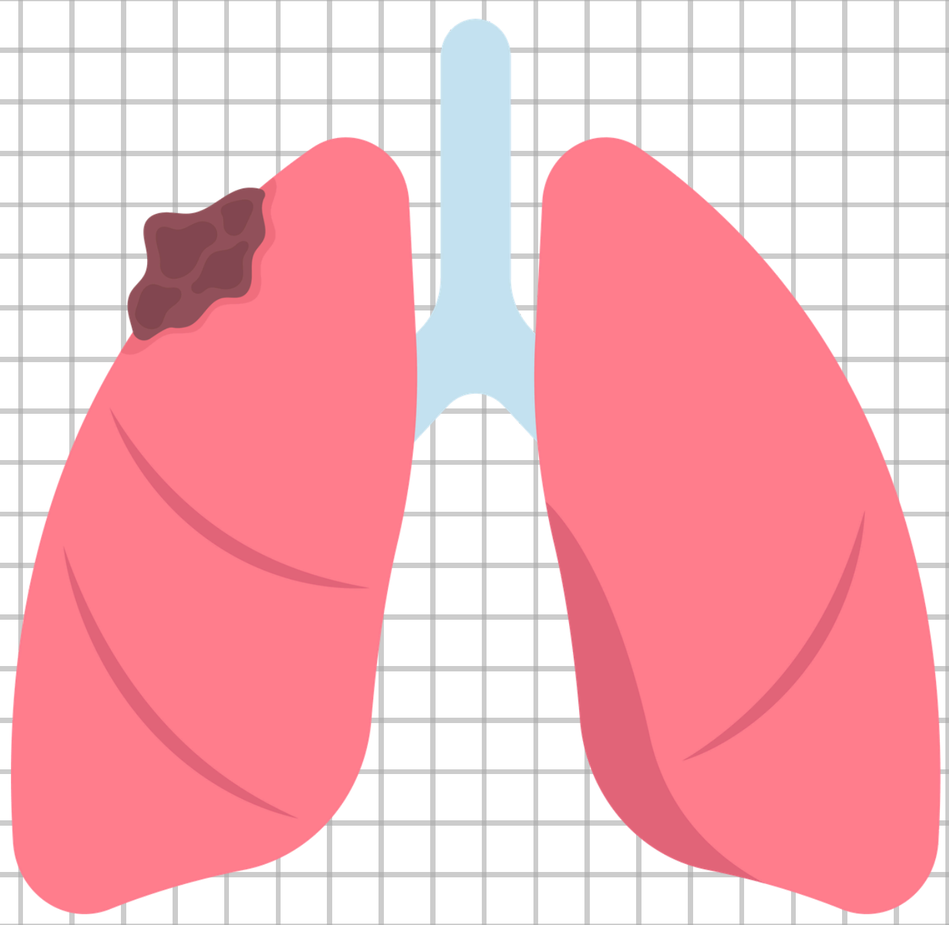
1 Inisiasi

- Tahap awal terbentuknya kanker akibat perubahan genetik dalam sel
- Misal: Karena bahan kimia atau radiasi yang merusak DNA sel

2 Promosi

- Sel yang telah terinisiasi mulai pembelahan yang berlebihan akibat rangsangan faktor segmen DNA yang terletak di hulu gen
- Bersifat reversibel, namun sangat penting karena meningkatkan jumalh sel abnormal

PATOGENESIS KANKER PARU



3 Konversi

- Merupakan titik kritis di mana sel abnormal berubah menjadi sel kanker ganas

4 Progresi

- Menandai perkembangan sel kanker menjadi lebih agresif dan bahaya
- Sel kanker mulai bertumbuh cepat dan menyerang jaringan di sekitarnya dan bisa menyebar ke bagian tubuh lainnya

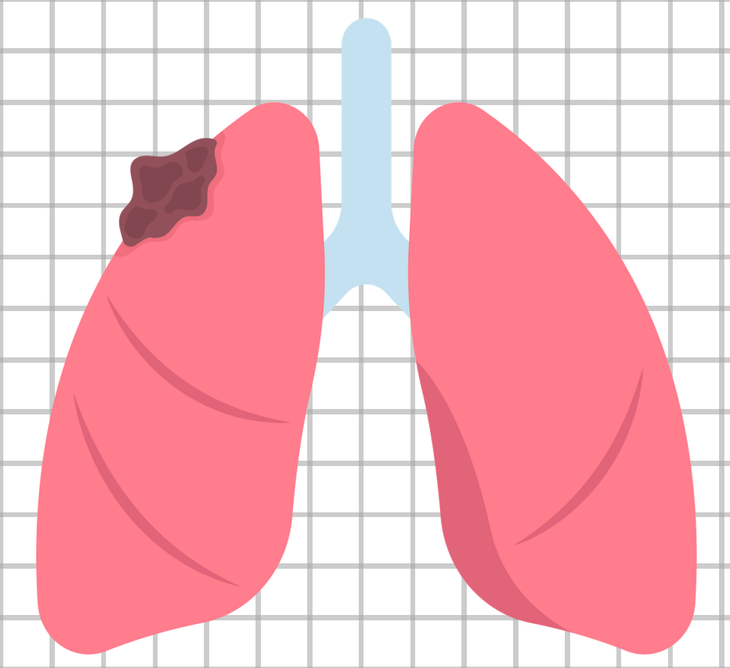
MUTASI GENETIK TERKAIT

Non-Small Cell Lung Cancer

- EGFR
- KRAS
- p16

Small Cell Lung Cancer

- MYC
- BCL2
- p53



MUTASI GENETIK TERKAIT (NSCLC)

1 EFGR

- Mengatur pertumbuhan, pembelahan dan kelangsungan hidup sel
- Umumnya ditemukan pada pasien non-perokok, Asia Timur dan permpuan
- menyebabkan pertumbuhan kanker

2 KRAS

- Terlibat dalam jalur transduksi yang mengatur pertumbuhan dan diferensiasi sel
- Ditemukan pada perokok, sulit diobati
- Memicu pertumbuhan sel kanker yang tidak terkontrol

3 p16

- Menjaga agar siklus sel tidak berjalan saat tidak diperlukan
- Mutasi umumnya terjadi pada NSCLC
- Kehilanga p16 dapat membuat siklus sel berjalan bebas, sehingga sel tidak terkontrol

MUTASI GENETIK TERKAIT (SCLC)

1 MYC

- Mengatur ekspresi gen yang berhubungan dengan pertumbuhan dan pembelahan sel
- Kanker menjadi lebih cepat tumbuh dan sulit diobati
- Kehilangan sel gen MYC dapat meningkatkan agresivitas kanker

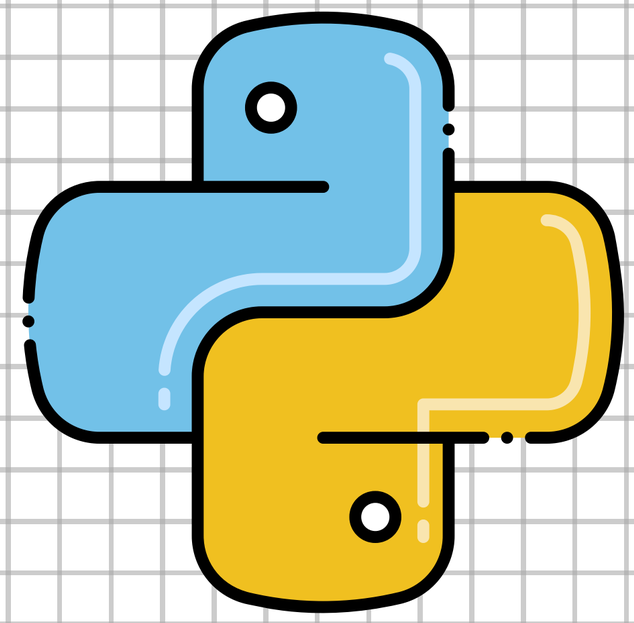
2 BCL2

- Berfungsi menghambat kematian sel terprogram
- >75% SCLC menunjukkan peningkatan ekspresi BCL2
- Jika mutasi akan membuat sel yang rusak tetap hidup dan berkembang

3 p53

- Berperan sebagai penjaga genom
- Menghentikan pembelahan sel jika terjadi kerusakan DNA
- Ditemukan sekitar 90% kasus SCLC menjadikan sel kanker sulit dikendalikan

PYTHON



Python

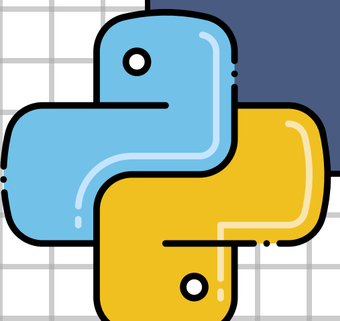
- Python adalah bahasa pemograman tingkat tinggi
- Digunakan luas dalam bidang data science dan maching learning
- Syntax sederhana dan mudah dipahami
- Bersifat open source dan cross platform

Keunggulan

- Syntax minimalis dan bersih
- Dokumentasi dan komunitas luas
- Integrasi baik dengan tools AI/ML

LIBRARY PENTING PYTHON

- Pandas
- Matplotlib
- Numpy
- Seaborn



MACHINE LEARNING

Definisi

Merupakan bagian dari kecerdasan buatan yang memiliki kemampuan belajar secara otomatis dan meningkatkan kemampuanny tanpa harus pemograman secara eksplisit



TAHAPAN MACHINE LEARNING

Pengumpulan data

Pre-processing

Model Training

Eksplorasi data

Evaluasi model





PENELITIAN TERKAIT

2020

Hubungan antara Kebiasaan Merokok dan Insiden Kanker Paru-paru

Islami, F., Torre, L. A., & Jemal, A.

Perbedaan Hasil Pengobatan Berdasarkan Lokasi Tumor

Maeda, R., Yoshida, J., et al.

2019

Risiko Kematian pada Pasien Kanker Paru dengan Diabetes.

Wang, X., Shen, T., et al.

PENELITIAN TERKAIT



2021

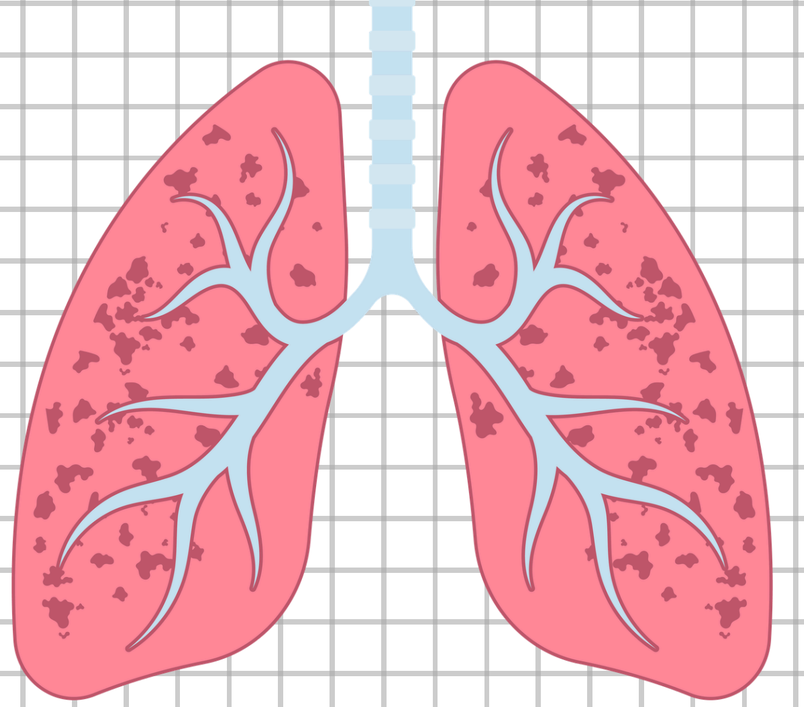
Pengaruh Gaya Hidup Sedentari terhadap Pertumbuhan Tumor

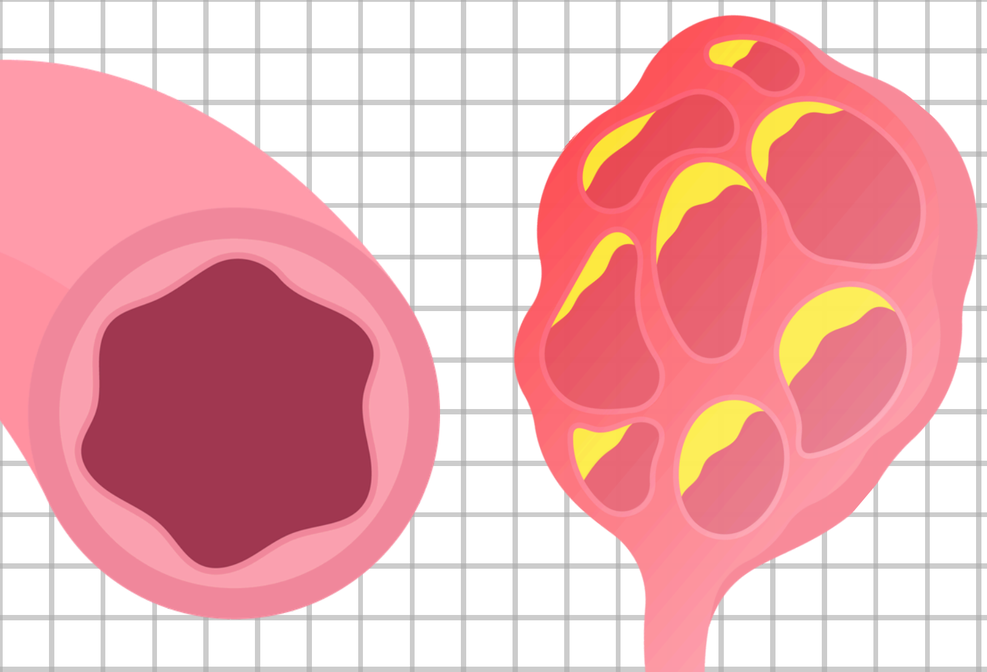
Zhang, Y., Ma, J., Zhou, Y., et al.

2022

Korelasi NLR dengan Prognosis Pasien Kanker Paru

Zhou, F., Zhang, L., Xie, F., et al.





BAB 3

Metodologi Penelitian

DATA PENELITIAN

Dataset “Lung Cancer Prediction” dari platform Kaggle yang dipublikasikan oleh The Devastator.

informasi mengenai pasien kanker paru-paru, memiliki 1000 entri data (baris) dan 25 atribut (fitur)



TAHAPAN PENELITIAN

1 Pengumpulan Data

Mengambil data dari dataset publik di Kaggle berjudul Lung Cancer Prediction.

2 Pre-Processing Data

Penghapusan data duplikat, pemeriksaan dan penanganan data yang kosong, transformasi data kategorikal ke bentuk numerik, dan normalisasi untuk data numerik.

3 Eksplorasi Data

Memahami pola distribusi data dan hubungan antar variabel melalui visualisasi untuk bisa mengetahui keterkaitan antara fitur dengan target

Melakukan analisi seleksi fitur dan menguji hubungan antara variabel independen (fitur) dengan variabel dependen (target) menggunakan Chi Square

TAHAPAN PENELITIAN

4 Pembangunan dan Pelatihan Model Machine Learning

Membagi data untuk training dan data untuk testing dengan rasio 7:3

Pembangunan empat model klasifikasi yang berbeda, yaitu Logistic Regression, Decision Tree Classifier, Random Forest Classifier, K-Nearest Neighbor, dan Support Vector Classifier

5 Evaluasi model

Mengevaluasi kinerja dari masing-masing model menggunakan metrik evaluasi

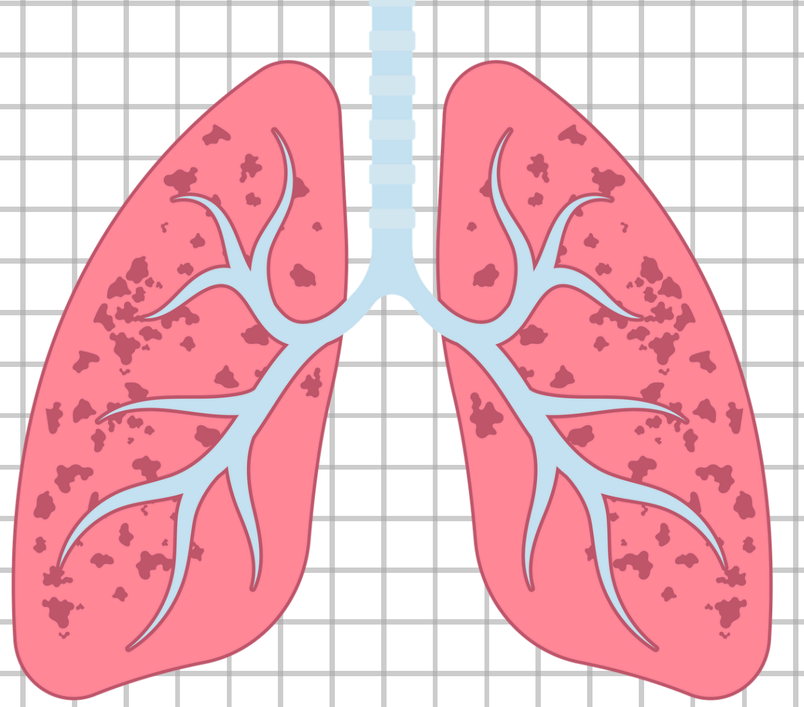
Akurasi - mengukur persentase prediksi yang benar

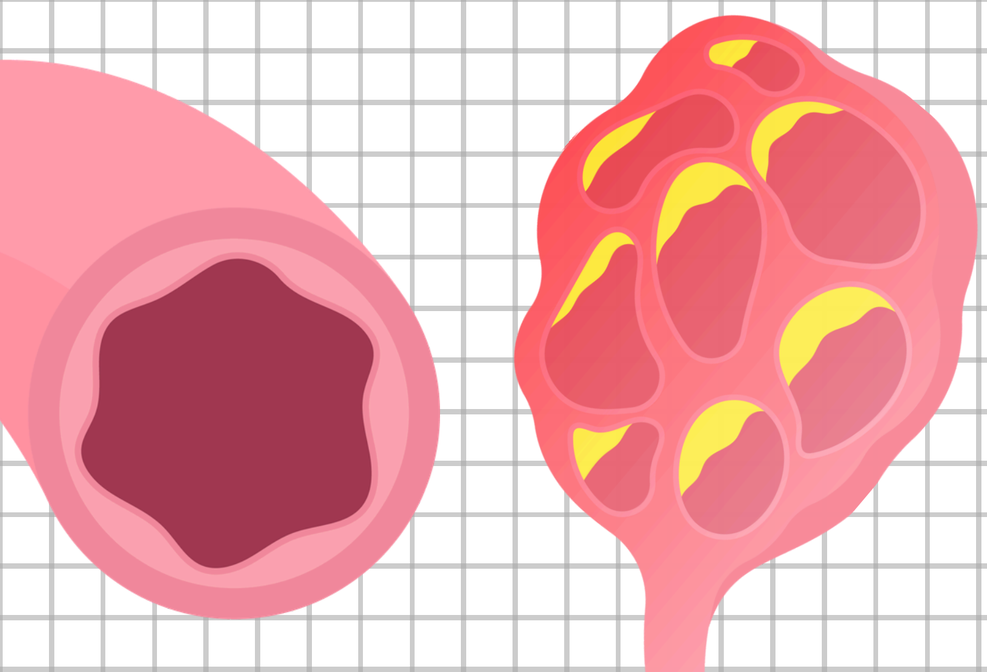
Precision, Recall, dan F1-score - menilai ketepatan dan sensitivitas prediksi

Confusion matrix - melihat distribusi hasil klasifikasi.

6 Menjawab Rumusan Masalah dan Menarik Kesimpulan

Melakukan analisis terhadap fitur-fitur yang paling berpengaruh dalam menentukan tingkat keparahan kanker berdasarkan prediksi dari model yang sudah dilatih dan diuji





BAB 4

Pembahasan

PRE-PROCESSING

```
data.info()
```

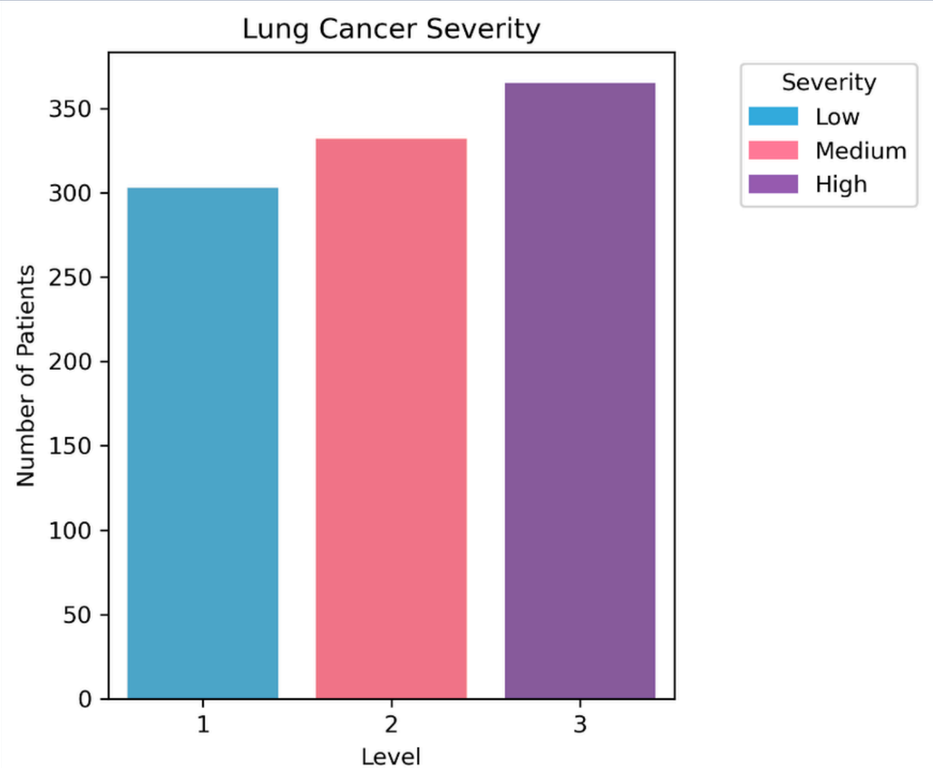
```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 26 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   index                     1000 non-null   int64
 1   Patient Id                1000 non-null   object
 2   Age                       1000 non-null   int64
 3   Gender                    1000 non-null   int64
 4   Air Pollution             1000 non-null   int64
 5   Alcohol use               1000 non-null   int64
 6   Dust Allergy              1000 non-null   int64
 7   OccuPational Hazards      1000 non-null   int64
 8   Genetic Risk              1000 non-null   int64
 9   chronic Lung Disease      1000 non-null   int64
 10  Balanced Diet             1000 non-null   int64
 11  Obesity                   1000 non-null   int64
 12  Smoking                   1000 non-null   int64
 13  Passive Smoker            1000 non-null   int64
 14  Chest Pain                1000 non-null   int64
 15  Coughing of Blood         1000 non-null   int64
 16  Fatigue                   1000 non-null   int64
 17  Weight Loss               1000 non-null   int64
 18  Shortness of Breath       1000 non-null   int64
 19  Wheezing                  1000 non-null   int64
 20  Swallowing Difficulty     1000 non-null   int64
 21  Clubbing of Finger Nails  1000 non-null   int64
 22  Frequent Cold             1000 non-null   int64
 23  Dry Cough                 1000 non-null   int64
 24  Snoring                   1000 non-null   int64
 25  Level                     1000 non-null   object
dtypes: int64(24), object(2)
memory usage: 203.3+ KB
```

```
data = data.drop_duplicates()
data.info()
```

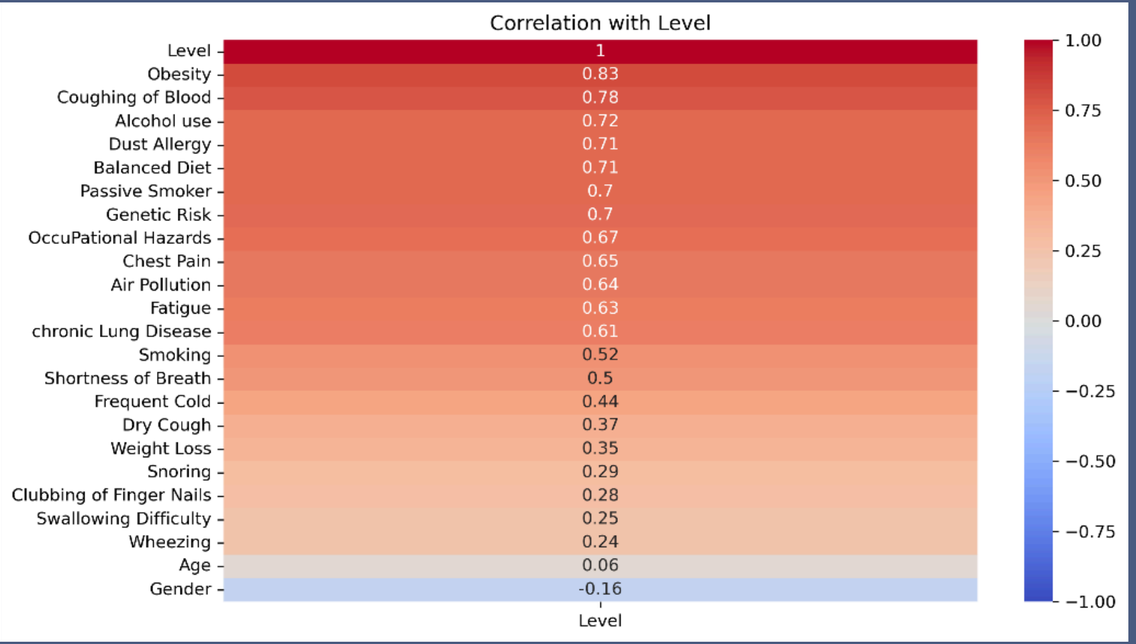
```
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 1000 entries, 0 to 999
Data columns (total 26 columns):
 #   Column                    Non-Null Count  Dtype
---  ------                    --------------  -----
 0   index                     1000 non-null   int64
 1   Patient Id                1000 non-null   object
 2   Age                       1000 non-null   int64
 3   Gender                    1000 non-null   int64
 4   Air Pollution             1000 non-null   int64
 5   Alcohol use               1000 non-null   int64
 6   Dust Allergy              1000 non-null   int64
 7   OccuPational Hazards      1000 non-null   int64
 8   Genetic Risk              1000 non-null   int64
 9   chronic Lung Disease      1000 non-null   int64
 10  Balanced Diet             1000 non-null   int64
 11  Obesity                   1000 non-null   int64
 12  Smoking                   1000 non-null   int64
 13  Passive Smoker            1000 non-null   int64
 14  Chest Pain                1000 non-null   int64
 15  Coughing of Blood         1000 non-null   int64
 16  Fatigue                   1000 non-null   int64
 17  Weight Loss               1000 non-null   int64
 18  Shortness of Breath       1000 non-null   int64
 19  Wheezing                  1000 non-null   int64
 20  Swallowing Difficulty     1000 non-null   int64
 21  Clubbing of Finger Nails  1000 non-null   int64
 22  Frequent Cold             1000 non-null   int64
 23  Dry Cough                 1000 non-null   int64
 24  Snoring                   1000 non-null   int64
 25  Level                     1000 non-null   object
dtypes: int64(24), object(2)
memory usage: 203.3+ KB
```

ANALISIS DATA EXPLORASI

Severity Level

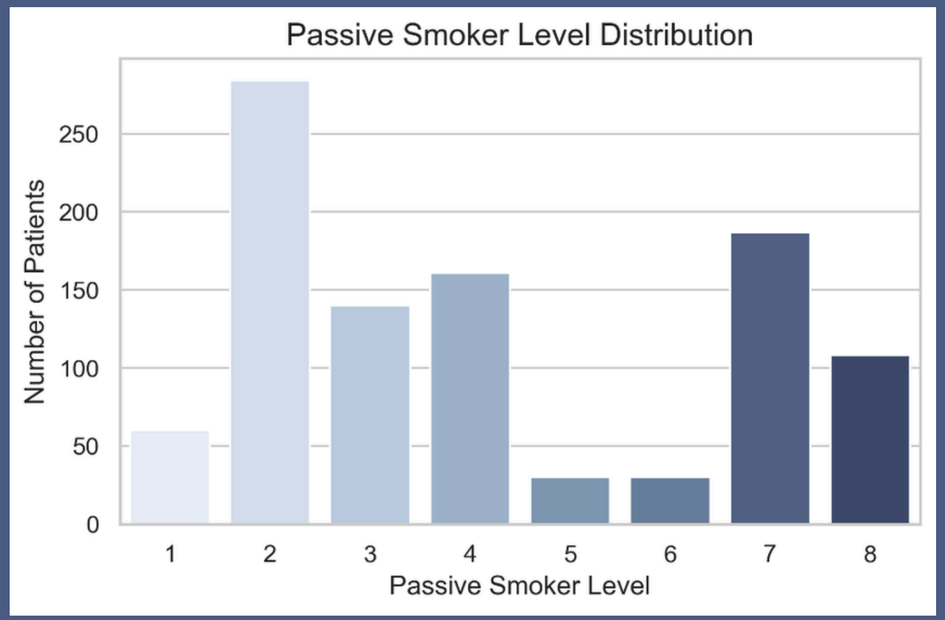


Correlation

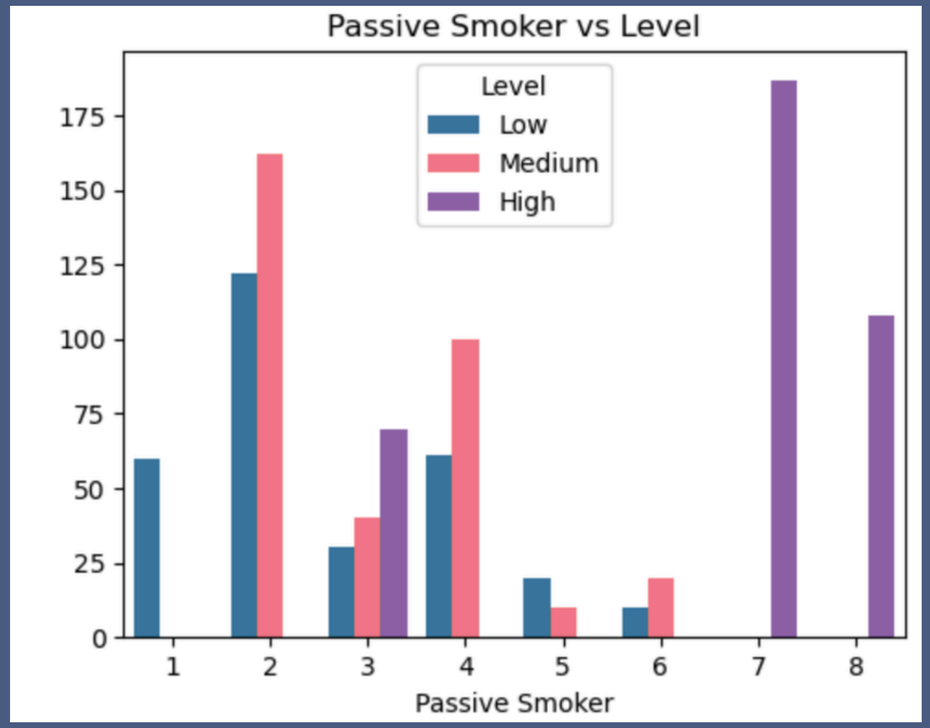


ANALISIS DATA EXPLORASI

Passive Smoker

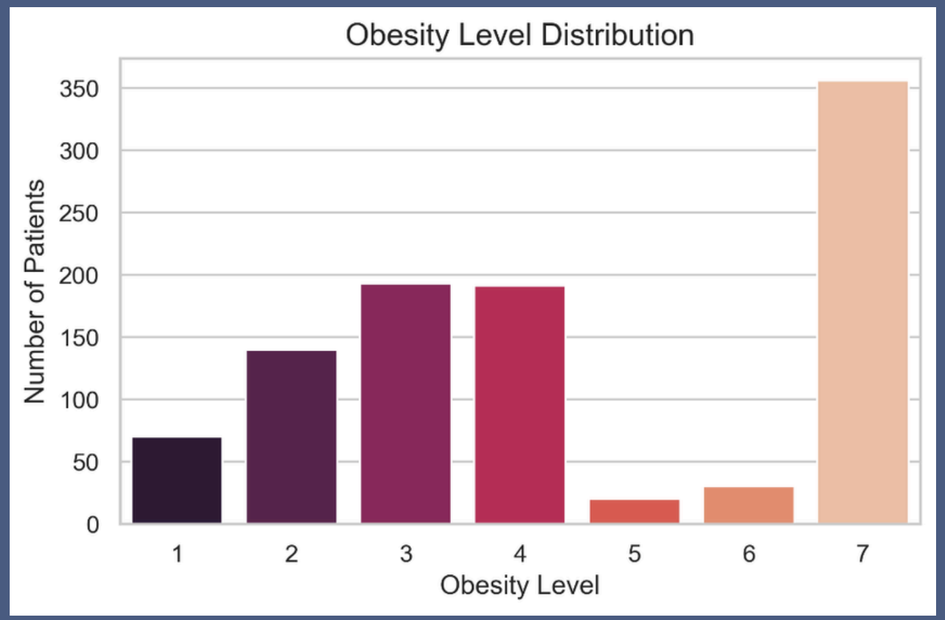


VS Level

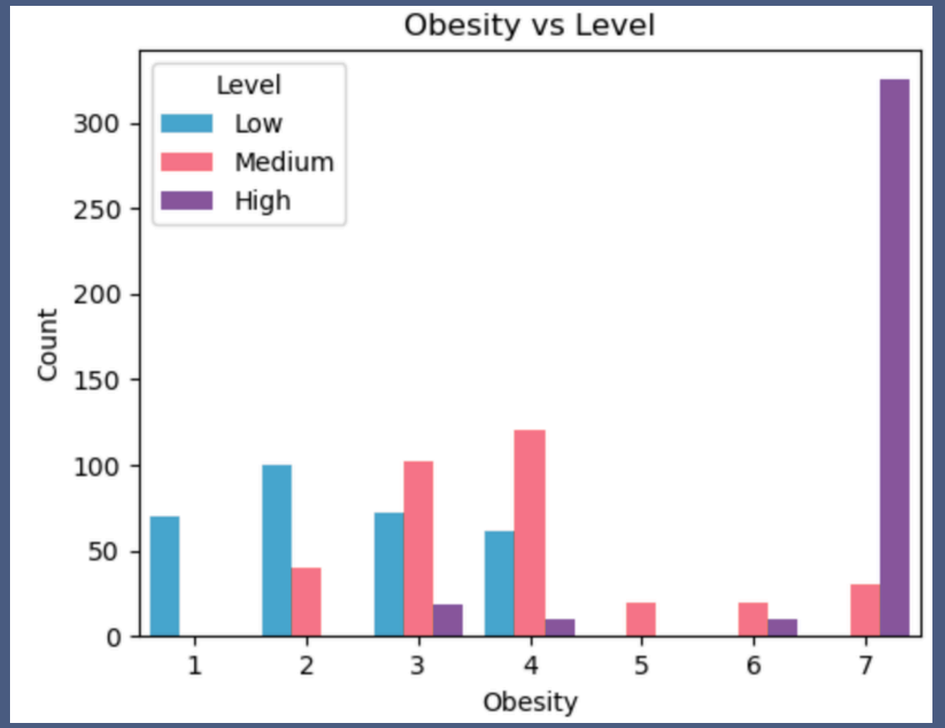


ANALISIS DATA EXPLORASI

Obesity

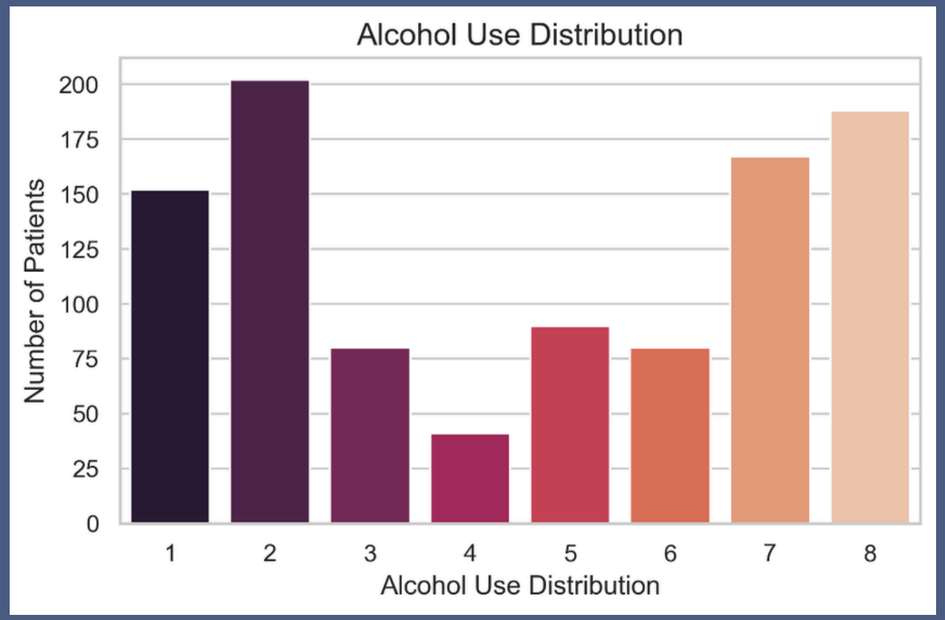


VS Level

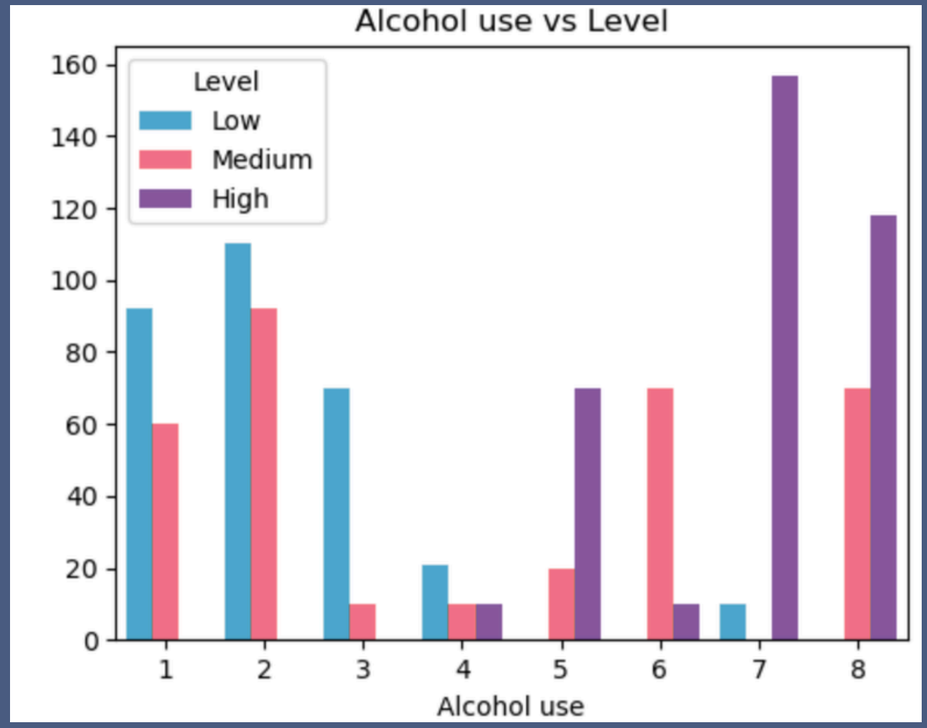


ANALISIS DATA EKSPLORASI

Alcohol Use

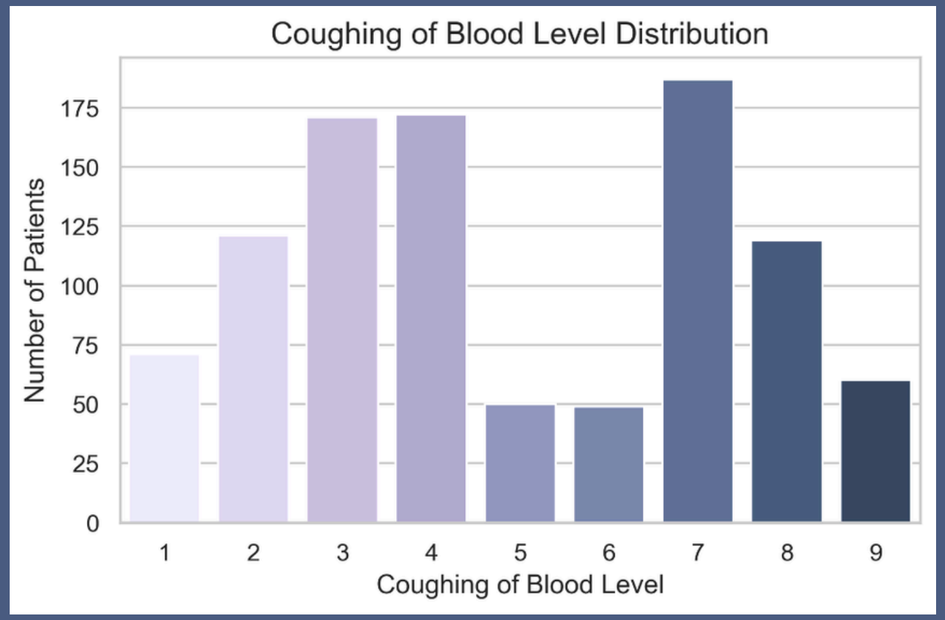


VS Level

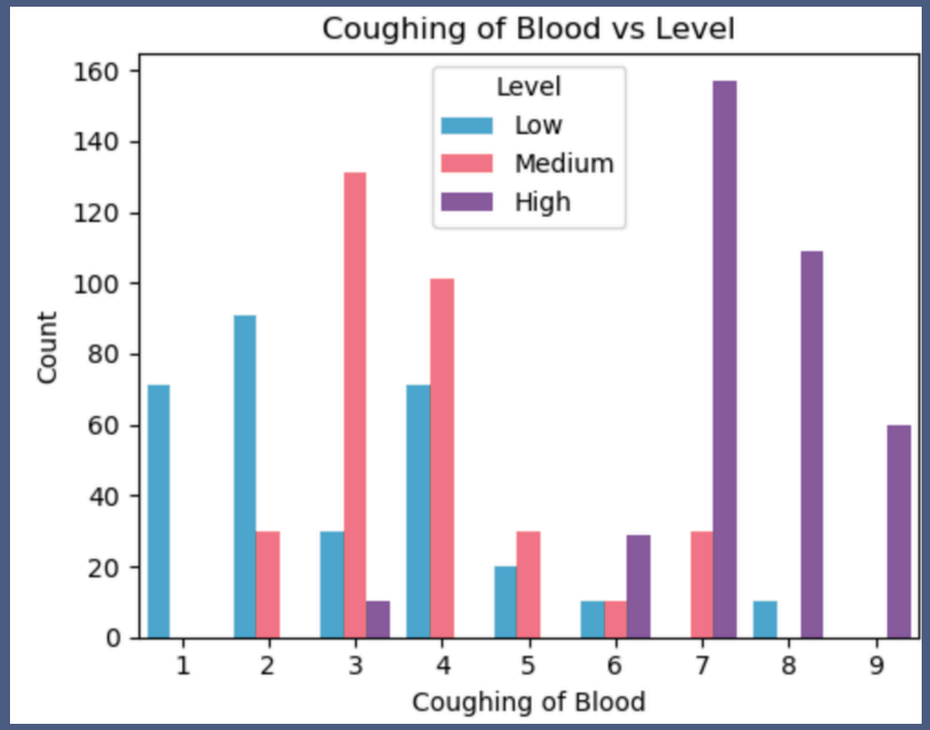


ANALISIS DATA EKSPLORASI

Coughing of Blood

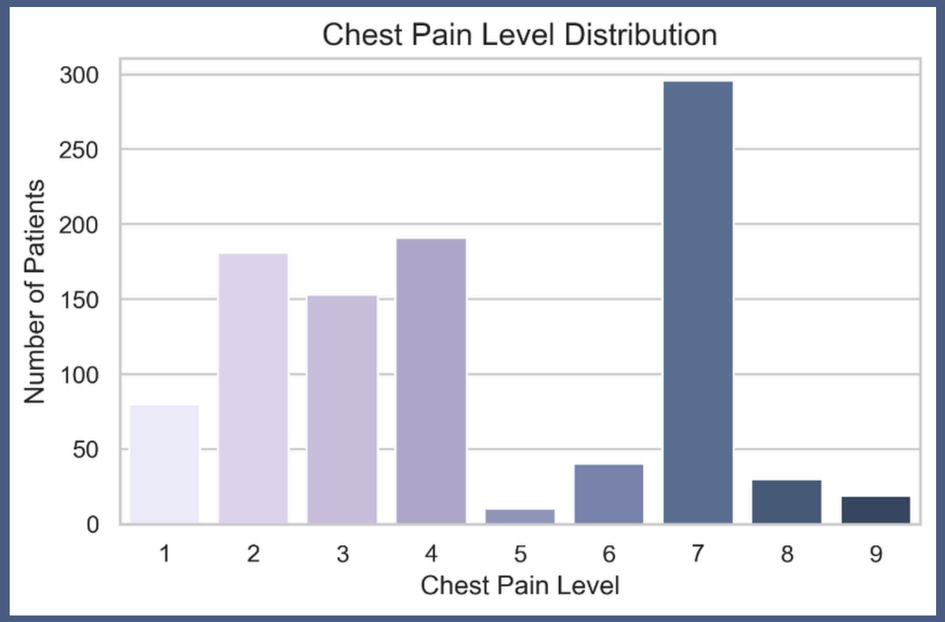


VS Level

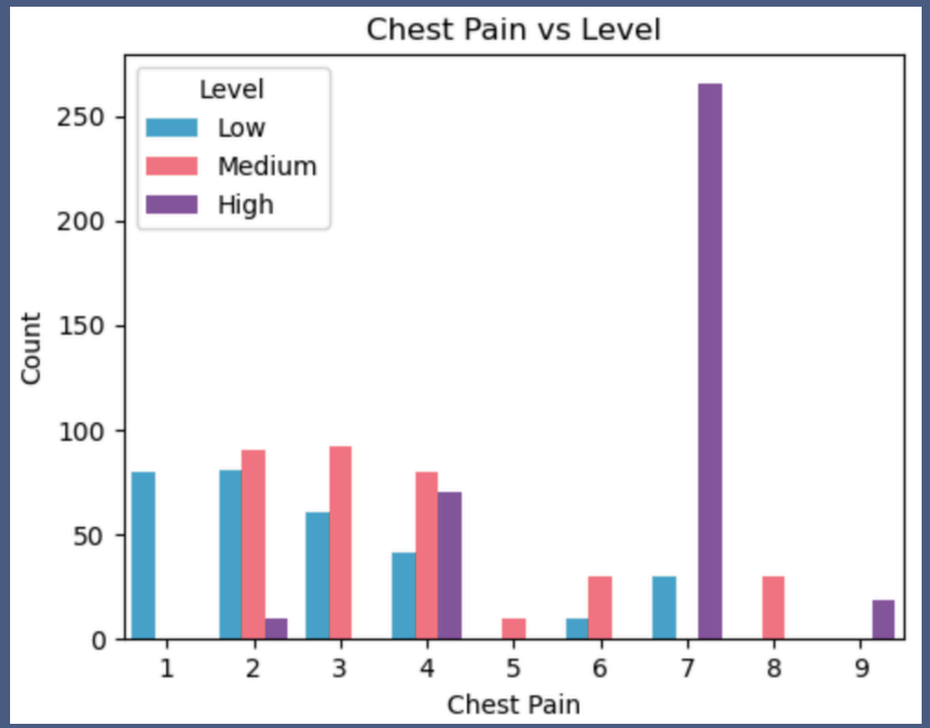


ANALISIS DATA EKSPLORASI

Chest Pain

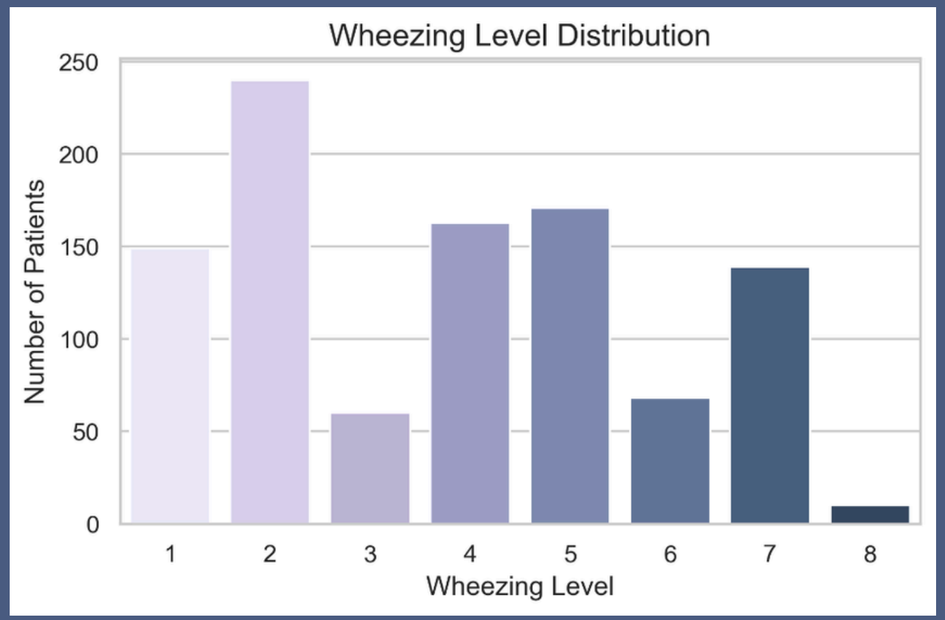


VS Level

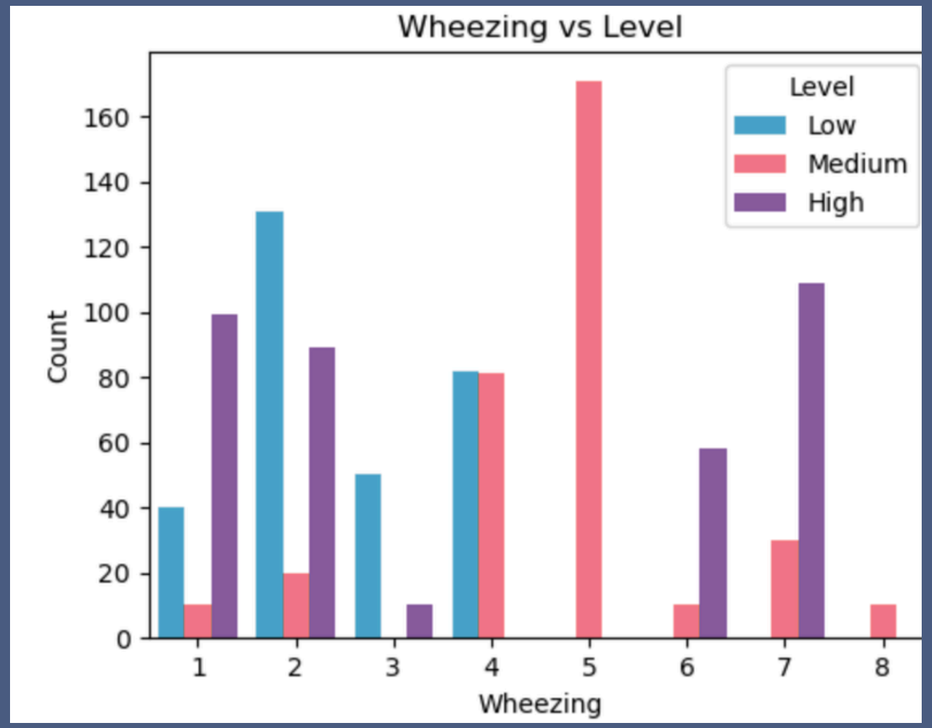


ANALISIS DATA EKSPLORASI

Wheezing



VS Level



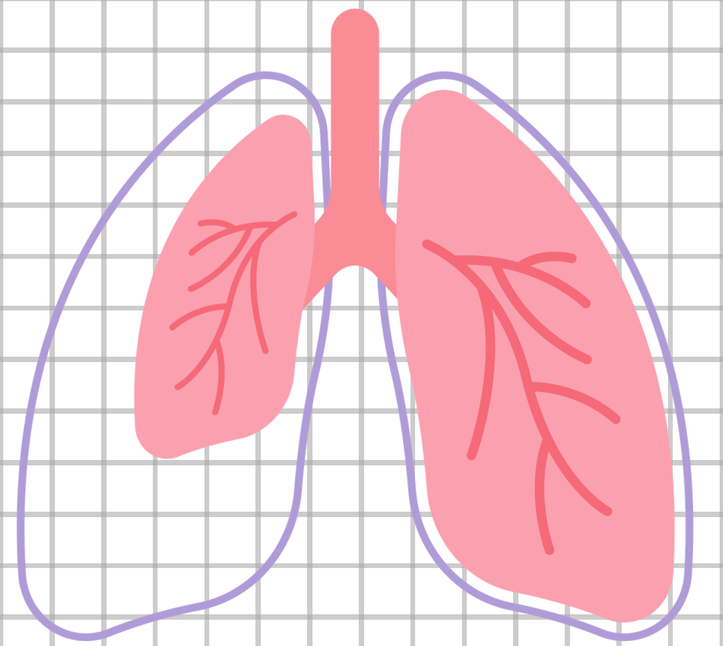
FAKTOR APA SAJA YANG BERKONTRIBUSI SIGNIFIKAN TERHADAP TINGKAT KEPARAHAN KANKER PARU-PARU?

Variabel Kategorik

'Air Pollution'
'Alcohol use'
'Occupational Hazards'
'Balanced Diet'
'Obesity'
'Smoking'
'Passive Smoker'
'Level'
'Genetic Risk'
'Chronic Lung Disease'
'Dust Allergy'
'Chest Pain'
'Coughing of Blood',
'Shortness of Breath',
'Swallowing Difficulty'
'Clubbing of Finger Nails'
'Fatigue'
'Weight Loss'
'Wheezing'
'Frequent Cold'
'Dry Cough'
'Snoring'
'Gender'

Variabel Numerik

'Age'



FAKTOR APA SAJA YANG BERKONTRIBUSI SIGNIFIKAN TERHADAP TINGKAT KEPARAHAN KANKER PARU-PARU?

Hipotesis

Kategorik

H0: Tidak ada relasi antara faktor kategorik dengan Level

H1: Ada relasi antara faktor kategorik dengan Level

Numerik

H0: Tidak ada perbedaan rata-rata antara semua kelompok Level

H1: Terdapat paling sedikit satu rata-rata yang berbeda antara semua kelompok Level

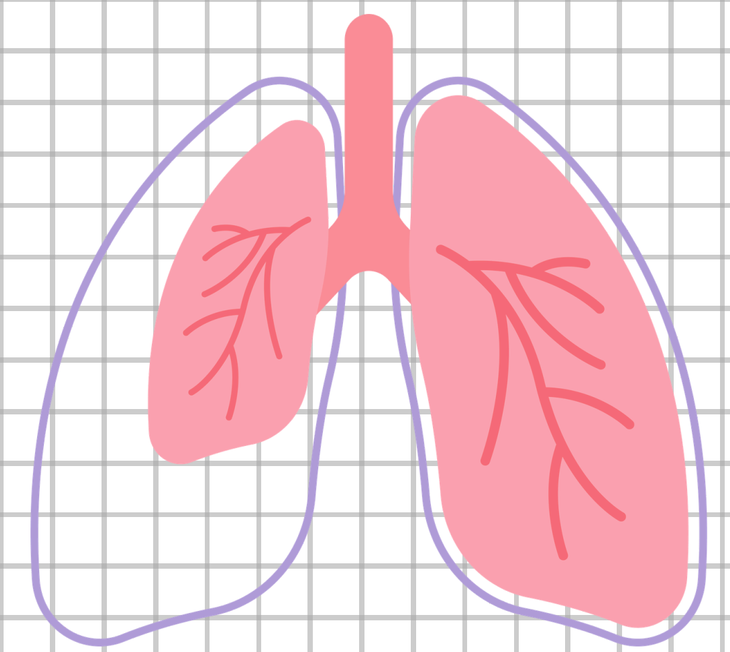
Alpha = 0.05

Tolak H0 jika p-value < alpha

Uji Statistik

Kategorik → Chi-Square Test

Numerik → Kruskal Wallis



HASIL UJI STATISTIK

Hasil Chi-Square

	Feature	Chi2 Score	P-Value
12	Coughing of Blood	818.668884	1.691651e-178
2	Alcohol use	781.909841	1.623436e-170
10	Passive Smoker	752.959791	3.139488e-164
8	Obesity	712.087562	2.355866e-155
9	Smoking	671.006253	1.962653e-146
7	Balanced Diet	588.933743	1.302155e-128
11	Chest Pain	524.489521	1.283948e-114
13	Fatigue	518.900446	2.099906e-113
1	Air Pollution	518.631533	2.402114e-113
5	Genetic Risk	488.649726	7.781445e-107
4	OccuPational Hazards	415.685654	5.432591e-91
3	Dust Allergy	401.040883	8.223917e-88
15	Shortness of Breath	330.880709	1.413081e-72
6	chronic Lung Disease	302.396157	2.165254e-66
18	Clubbing of Finger Nails	257.907679	9.909666e-57
14	Weight Loss	206.666563	1.327169e-45
16	Wheezing	201.426189	1.823303e-44
19	Frequent Cold	192.713276	1.421818e-42
20	Dry Cough	152.029547	9.709645e-34
17	Swallowing Difficulty	113.074249	2.794079e-25
21	Snoring	91.748155	1.194376e-20
0	Gender	4.668165	9.689936e-02

Hasil Kruskal Wallis

H-statistic: 14.89720569957511

P-value: 0.0005822545412255028



INTERPRETASI & KONKLUSI

Interpretasi

Dapat dilihat dari hasil uji Chi-Square bahwa semua variabel kecuali Gender mempunyai p-value < 0.05. Maka H0 ditolak untuk semua variabel kecuali Gender.

Dari hasil Kruskal Wallis, dapat dilihat bahwa p-value < 0.05. Maka H0 ditolak.

Konklusi

Dapat disimpulkan bahwa semua variabel kecuali Gender berpengaruh signifikan terhadap Level.

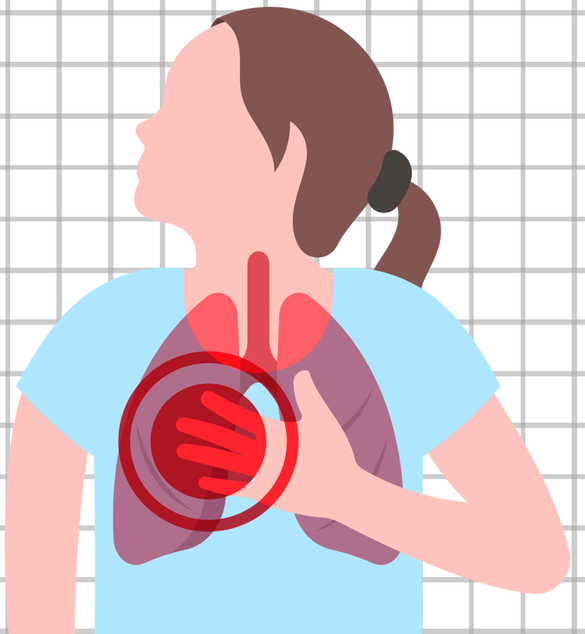
BAGAIMANA FAKTOR-FAKTOR YANG BERKONTRIBUSI SIGNIFIKAN DAPAT MEMPREDIKSI TINGKAT KEPARAHAN KANKER PARU-PARU?

Variabel Xi :

'Air Pollution'
'Alcohol use'
'Occupational Hazards'
'Balanced Diet'
'Obesity'
'Smoking'
'Passive Smoker'
'Age'
'Genetic Risk'
'Chronic Lung Disease'
'Dust Allergy'
'Chest Pain'
'Coughing of Blood',
'Shortness of Breath',
'Swallowing Difficulty'
'Clubbing of Finger Nails'
'Fatigue'
'Weight Loss'
'Wheezing'
'Frequent Cold'
'Dry Cough'
'Snoring'

Variabel Y:

'Level'



HASIL LOGISTIC REGRESSION

Logistic Regression

	precision	recall	f1-score	support
High	1.00	1.00	1.00	120
Low	1.00	1.00	1.00	92
Medium	1.00	1.00	1.00	88
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```

HASIL DECISION TREE

Decision Tree

	precision	recall	f1-score	support
High	1.00	1.00	1.00	120
Low	1.00	1.00	1.00	92
Medium	1.00	1.00	1.00	88
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```

HASIL RANDOM FOREST

Random Forest

	precision	recall	f1-score	support
High	1.00	1.00	1.00	120
Low	1.00	1.00	1.00	92
Medium	1.00	1.00	1.00	88
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```

HASIL SUPPORT VECTOR MACHINE

SVM

	precision	recall	f1-score	support
High	1.00	1.00	1.00	120
Low	1.00	1.00	1.00	92
Medium	1.00	1.00	1.00	88
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [0.98  0.96  0.98  0.98  0.975]
Average CV Score:  0.975
Number of CV Scores used in Average:  5
```

HASIL K-NEAREST NEIGHBOURS

KNN

	precision	recall	f1-score	support
High	1.00	1.00	1.00	120
Low	1.00	1.00	1.00	92
Medium	1.00	1.00	1.00	88
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [0.995 1.    1.    1.    0.995]
Average CV Score:  0.998
Number of CV Scores used in Average:  5
```

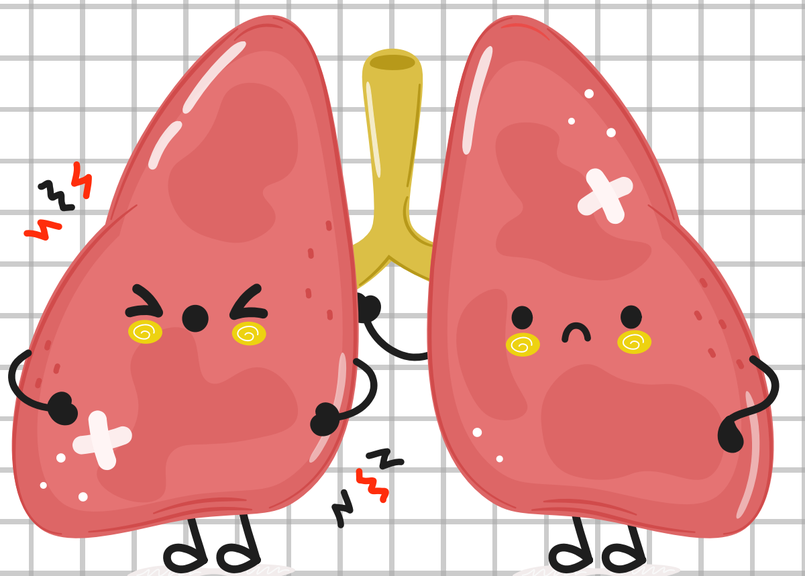
BAGAIMANA HUBUNGAN ANTARA FAKTOR GAYA HIDUP DAN LINGKUNGAN DENGAN TINGKAT KEPARAHAN KANKER PARU-PARU?

Variabel Xi :

'Alcohol use'
'Balanced Diet'
'Obesity'
'Smoking'
'Air Pollution'
'Occupational Hazards'
'Passive Smoker'

Variabel Y:

'Level'



HASIL LOGISTIC REGRESSION

Logistic Regression:

	precision	recall	f1-score	support
High	0.89	0.97	0.93	98
Low	0.64	0.82	0.72	93
Medium	0.73	0.50	0.60	109
accuracy			0.75	300
macro avg	0.76	0.76	0.75	300
weighted avg	0.76	0.75	0.74	300



HASIL DECISION TREE

Decision Tree:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	1.00	1.00	1.00	93
Medium	1.00	1.00	1.00	109
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```



HASIL RANDOM FOREST

Decision Tree:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	1.00	1.00	1.00	93
Medium	1.00	1.00	1.00	109
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```



HASIL SUPPORT VECTOR MACHINE

SVM:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	0.76	0.97	0.85	93
Medium	0.96	0.74	0.84	109
accuracy			0.90	300
macro avg	0.91	0.90	0.90	300
weighted avg	0.91	0.90	0.90	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```



HASIL K-NEAREST NEIGHBORS

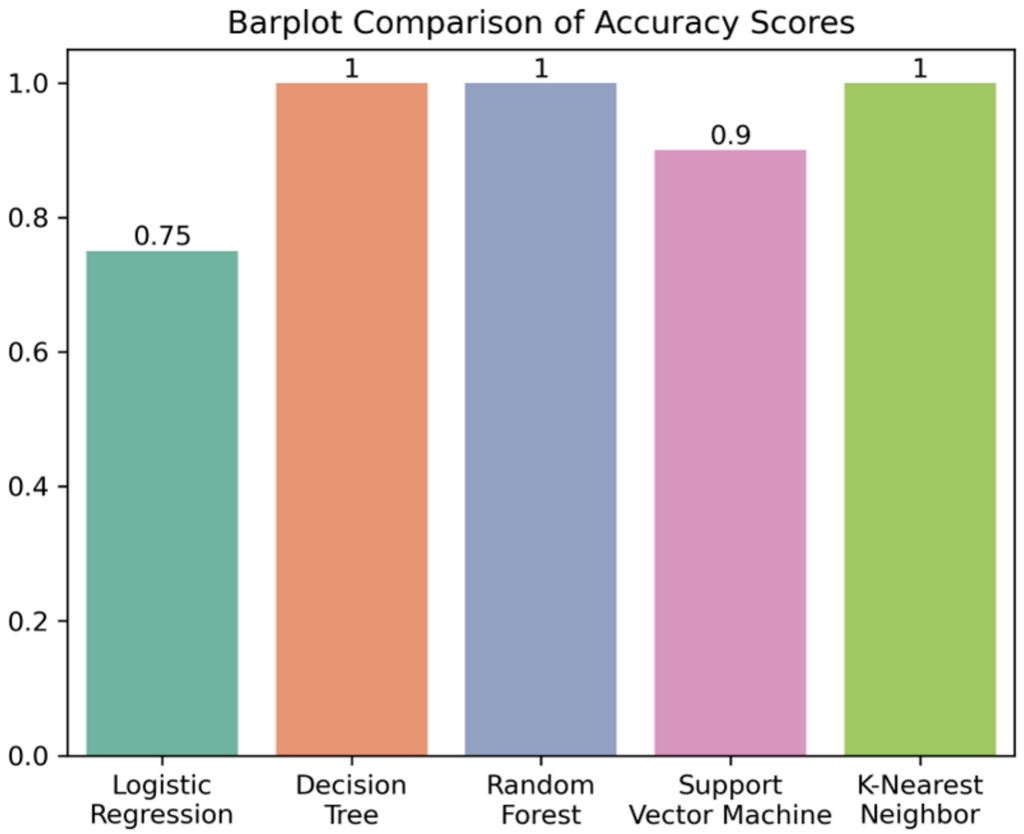
KNN:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	1.00	1.00	1.00	93
Medium	1.00	1.00	1.00	109
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```



PEMILIHAN MODEL TERBAIK !!!

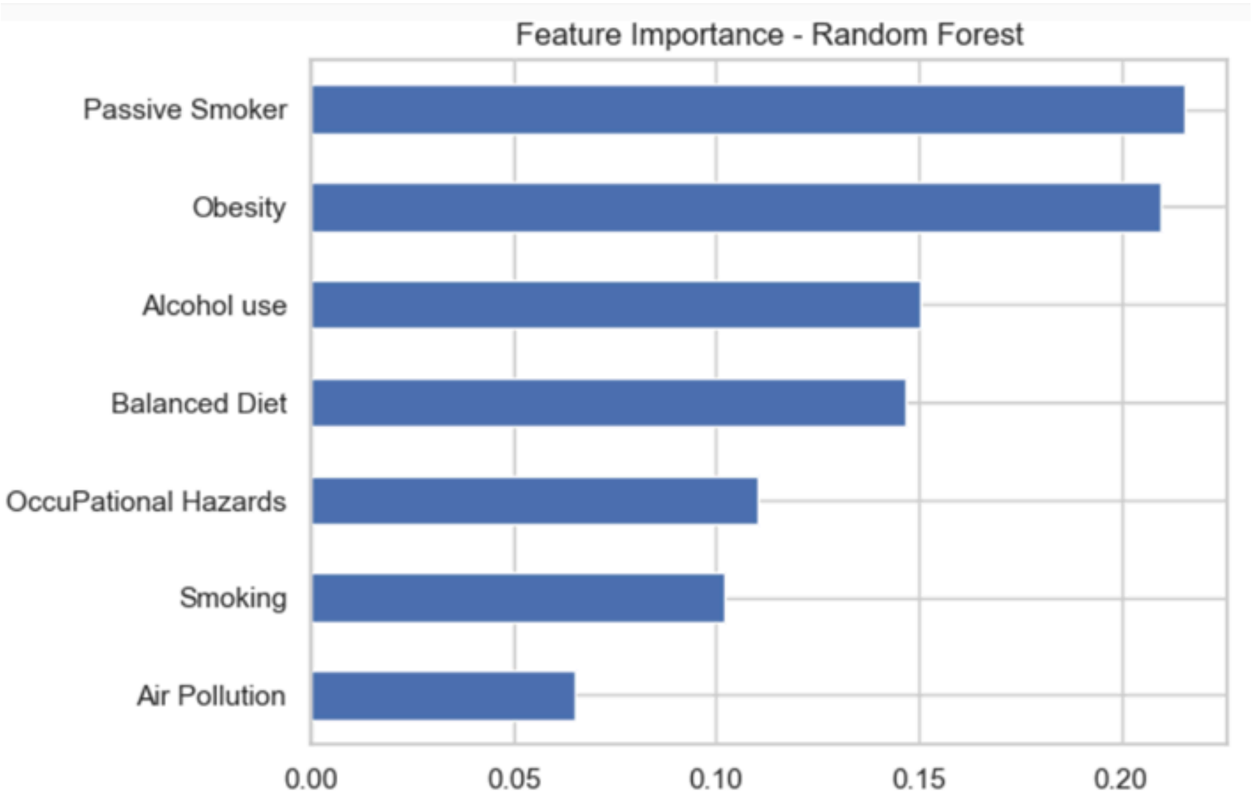




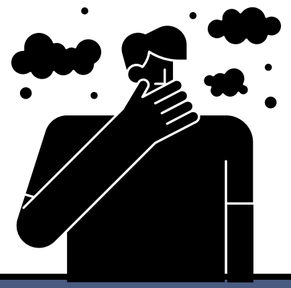


FEATURE IMPORTANCE











BAGAIMANA HUBUNGAN ANTARA GEJALA KLINIS DENGAN TINGKAT KEPARAHAN KANKER PARU-PARU?

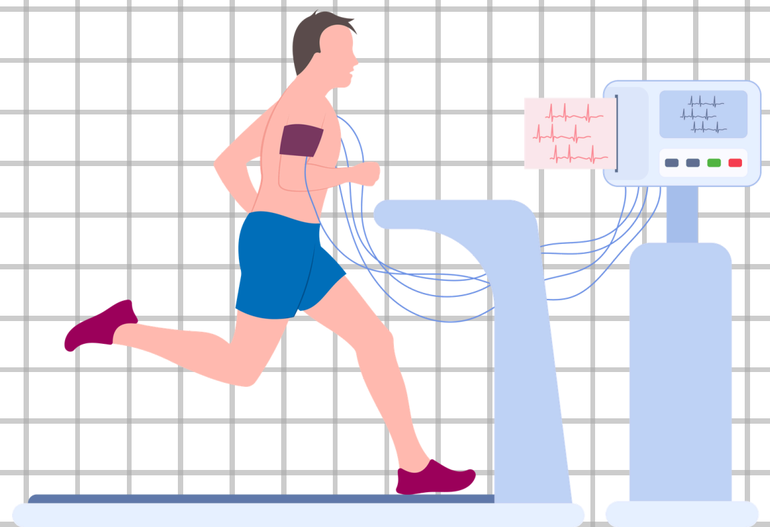
Variabel Xi :

'Chest Pain'
'Coughing of Blood',
'Shortness of Breath',
'Swallowing Difficulty'
'Clubbing of Finger Nails'

'Fatigue'
'Weight Loss'
'Wheezing'
'Frequent Cold'
'Dry Cough'
'Snoring'

Variabel Y:

'Level'



HASIL LOGISTIC REGRESSION

Logistic Regression:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	0.95	0.98	0.96	93
Medium	0.98	0.95	0.97	109
accuracy			0.98	300
macro avg	0.98	0.98	0.98	300
weighted avg	0.98	0.98	0.98	300

Cross Validation Scores: [1. 1. 1. 1. 1.]
Average CV Score: 1.0
Number of CV Scores used in Average: 5



HASIL DECISION TREE

Decision Tree:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	1.00	1.00	1.00	93
Medium	1.00	1.00	1.00	109
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```



HASIL RANDOM FOREST

Random Forest:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	1.00	1.00	1.00	93
Medium	1.00	1.00	1.00	109
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```



HASIL SUPPORT VECTOR MACHINE

SVM:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	1.00	0.98	0.99	93
Medium	0.98	1.00	0.99	109
accuracy			0.99	300
macro avg	0.99	0.99	0.99	300
weighted avg	0.99	0.99	0.99	300



HASIL K-NEAREST NEIGHBORS

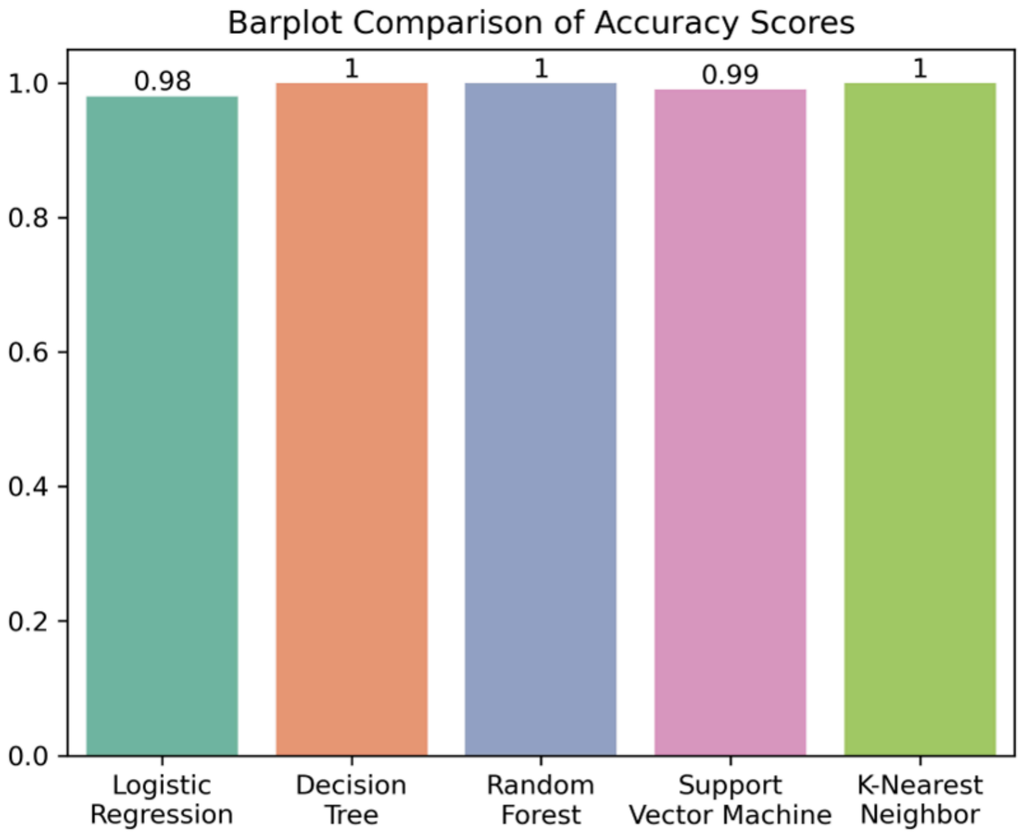
KNN:

	precision	recall	f1-score	support
High	1.00	1.00	1.00	98
Low	1.00	1.00	1.00	93
Medium	1.00	1.00	1.00	109
accuracy			1.00	300
macro avg	1.00	1.00	1.00	300
weighted avg	1.00	1.00	1.00	300

```
Cross Validation Scores:  [1. 1. 1. 1. 1.]
Average CV Score:  1.0
Number of CV Scores used in Average:  5
```



PEMILIHAN MODEL TERBAIK !!!





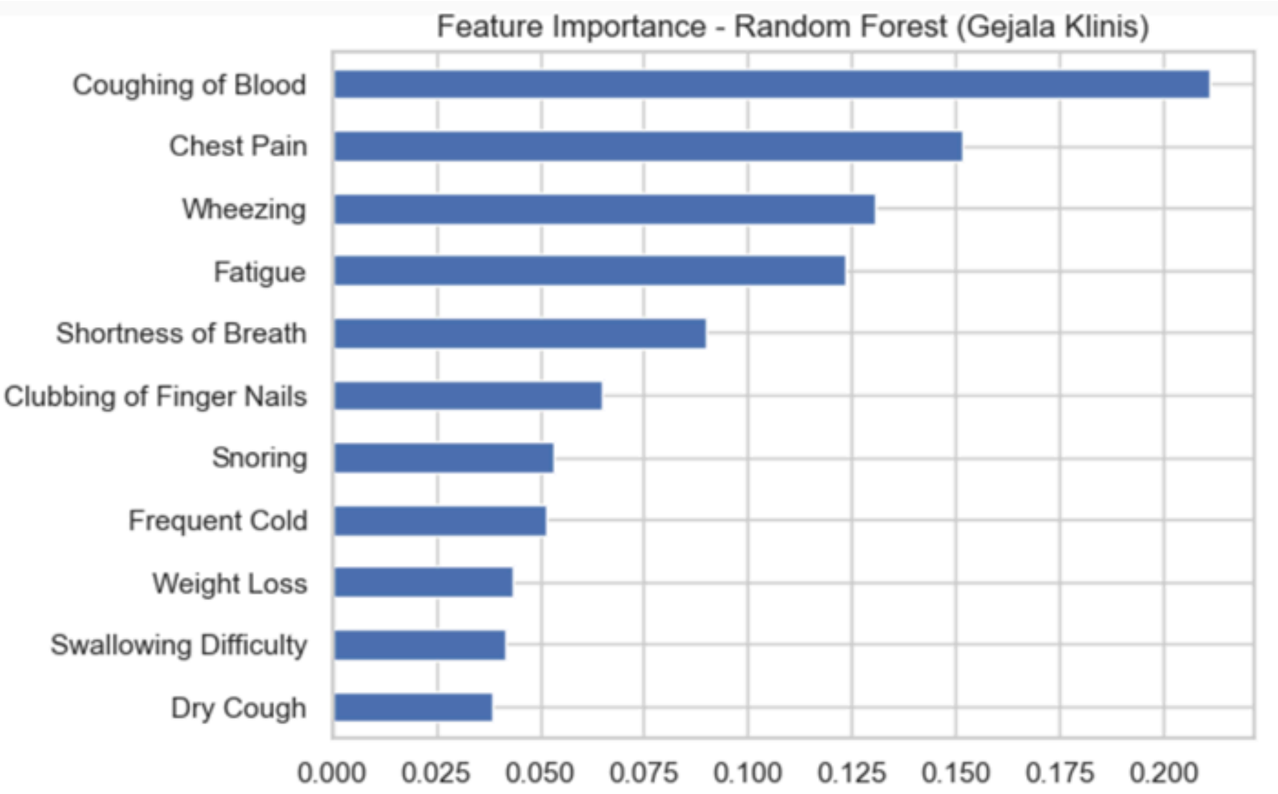


FEATURE IMPORTANCE

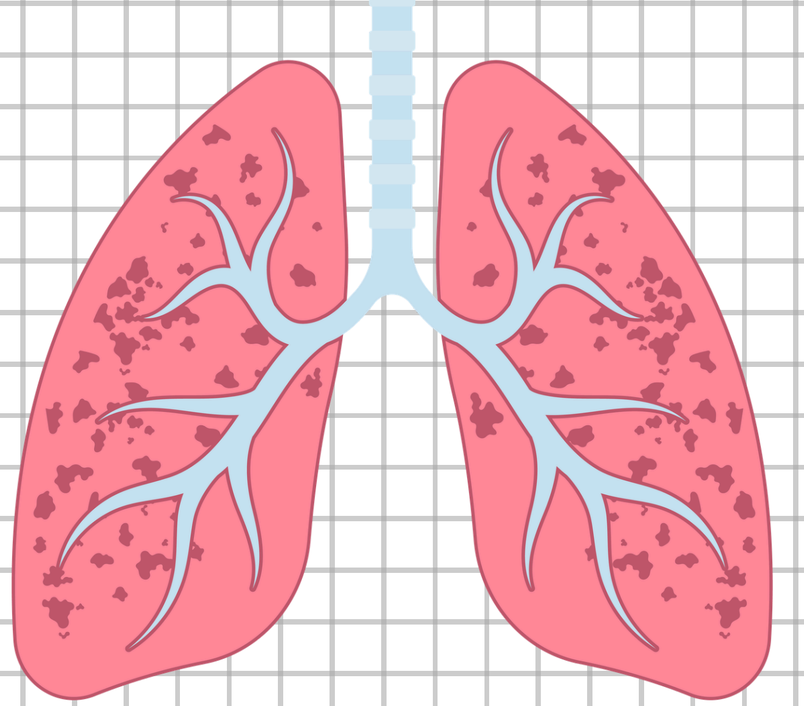
zzzz

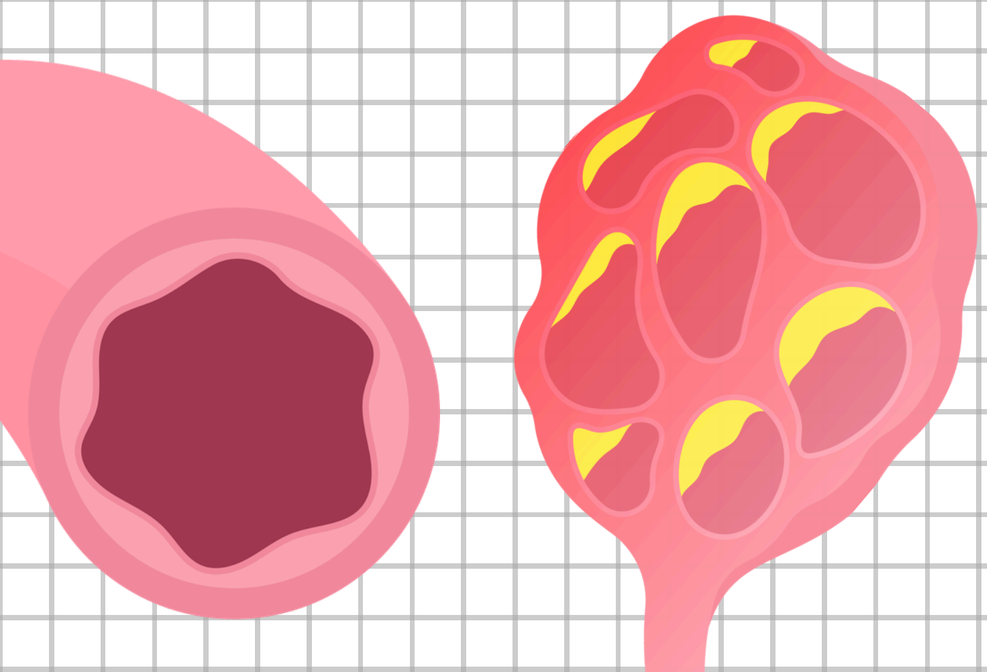












BAB 5

Kesimpulan

KESIMPULAN

1. Hanya variabel Gender yang tidak berpengaruh signifikan
2. Model Random Forest, Decision Tree, dan K-Nearest Neighbor adalah model dengan akurasi terbaik.
3. Tiga faktor gaya hidup dan lingkungan yang paling berpengaruh pada prediksi adalah ‘Passive Smoker’, ‘Obesity’, dan ‘Alcohol Use’
4. Tiga faktor gejala yang paling berpengaruh pada prediksi adalah ‘Coughing of Blood’, ‘Chest Pain’, dan ‘Wheezing’

Sumber

Bray, F., Laversanne, M., Sung, H., Ferlay, J., Siegel, R. L., Soerjomataram, I., Jemal, A. (2024). Global Cancer Statistics 2022: GLOBOCAN Estimates of Incidence and Mortality Worldwide for 36 Cancers in 185 Countries. CA: A Cancer Journal for Clinicians, 73(1), 234. https://doi.org/10.3322/caac.21834

World Health Organization. (2023). Cancer: Key Facts. https://www.who.int/news-room/fact-sheets/detail/lung-cancer

Jose, K. N., et al. (2023). Demographic and Clinical Characteristics of Primary Lung Cancer Patients in Kerala: Analysis of Data from Six Teaching Centers. Journal of Medicine and Primary Care, 12(10), 2501-2506. https://doi.org/10.4103/jfmpc.jfmpc_2176_22

McDowell, S. (2020). Study: Young Women Now Have Higher Rates for Lung Cancer Than Men Worldwide. American Social Society. https://www.cancer.org/research/acs-research-news/study-young-women-now-have-higher-rate-for-lung-cancer-than-men-worldwide.html

Herlina, H., Siti Rahmalia, H.D., Dewi, Y. I. (2014). Hubungan Riwayat Merokok dengan Stadium Ca Paru. Jurnal Online Mahasiswa Program Studi Ilmu Keperawatan Universitas Riau, 1(1) 1-5. https://jom.unri.ac.id/index.php/JOMPSIK/article/view/3478

Du, Y., et al. (2020). Lung Cancer Occurrence Attributable to Passive Smoking Among Never Smokers in China: A Systematic Review and Meta-analysis. National Library of Medicine: Translational Lung Cancer Research, 9(2), 204-205. https://doi.org/10.21037/tlcr.2020.02.11

Islam, K. M., Jiang, X., Anggondowati, T., Lin, G., Ganti, A. K. (2015). Comorbidity and Survival in Lung Cancer Patients. Cancer Epidomiolohy, Biomarkers & Prevention, 24(7), 1079 – 1083. https://doi.org/10.1158/1055-9965.EPI-15-0036

Sumber

Kourou, K., Exarchos, T. P., Exarchos, K. P., Karamouzis, M. V., Fotiadis, D. I. (2015). Machine Learning Applications in Cancer Prognosis and Prediction. Computational and Structural Biotechnology Journal, 13, 8-16. https://doi.org/10.1016/j.csbj.2014.11.005

Shankar A, Dubey A, Saini D, Singh M, Prasad CP, Roy S, Bharati SJ, Rinki M, Singh N, Seth T, Khanna M, Sethi N, Kumar S, Sirohi B, Mohan A, Guleria R, Rath GK. (2019) Environmental and occupational determinants of lung cancer. Transl Lung Cancer Res. 8(Suppl 1), S31-S49. https://doi.org/10.21037/tlcr.2019.03.05

Cleveland Clinic. (2022). Lung Cancer. https://my.clevelandclinic.org/health/diseases/4375-lung-cancer#overview

Siddiqui F, Vaqar S, Siddiqui AH. (2025). StatPearls [Internet]. StatPearls Publishing. https://www.ncbi.nlm.nih.gov/books/NBK482357/

Kim, J., Lee, H., Huang, B. W. (2022). Lung Cancer: Diagnosis, Treatment, Principles, and Screening. Am Fam Physician, 105(5), 487. https://www.aafp.org/pubs/afp/issues/2022/0500/p487.html#afp20220500p487-b1

Weston A & Harris CC. (2003). Holland-Frei Cancer Medicine 6th Edition. BC Decker. https://www.ncbi.nlm.nih.gov/books/NBK13982/

McKinney, W. (2011). pandas: a foundational Python library for data analysis and statistics. Python for high performance and scientific computing, 14(9), 1-9. https://www.academia.edu/download/117768488/pyhpc2011_submission_9.pdf

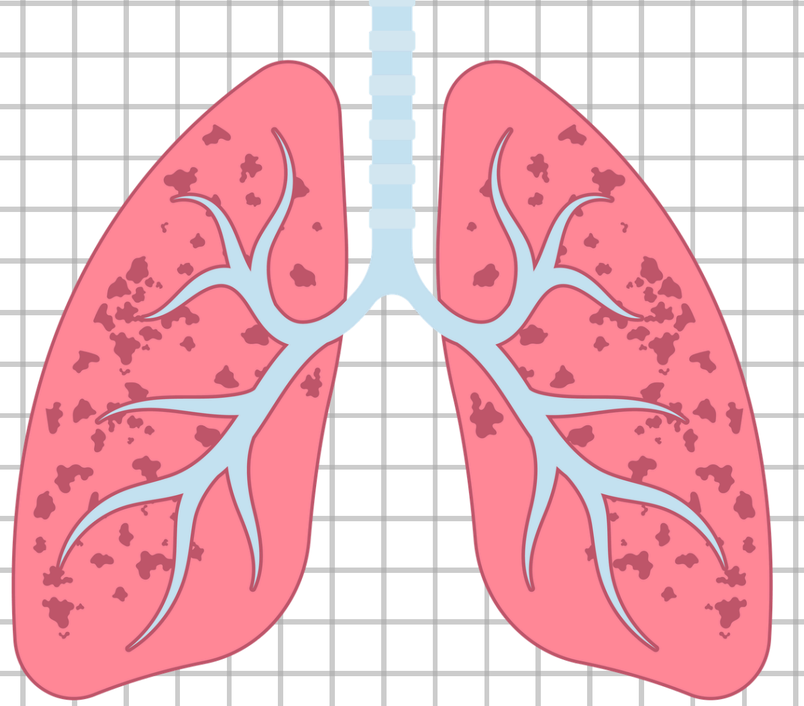
McKinney, W. (2012). Python for data analysis: Data wrangling with Pandas, NumPy, and IPython. O'Reilly Media, Inc. https://www.google.com/books?hl=id&lr=&id=v3n4_AK8vu0C&oi=fnd&pg=PR3&dq=library+python+pandas&ots=riHL5ixxsB&sig=Qm7zhIprKNwv4jsYAMvltYrCAqA

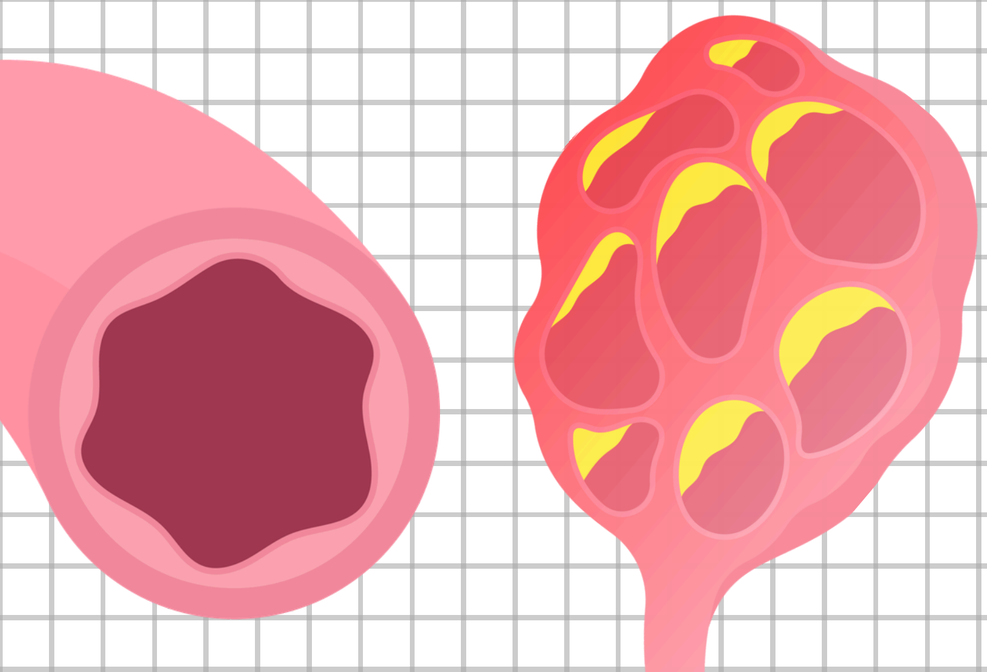
Sumber

Kusuma, P. D. (2020). Machine Learning Teori, Program, dan Studi Kasus. Deepublish. https://www.google.com/books?hl=id&lr=&id=wDVaEQAAQBAJ&oi=fnd&pg=PP1&dq=penjelasan+machine+learning&ots=j0IRV29iXB&sig=bHoZHwzoEX_e_0vz5V18kcPb27c

Daqiqil Id, I. (2022). Machine learning: Teori, studi kasus dan implementasi menggunakan Python. Unri Press. https://www.google.com/books?hl=id&lr=&id=JvBPEAAAQBAJ&oi=fnd&pg=PA1&dq=teori+machine+learning&ots=j-0nODydhy&sig=Lie5s5svizkD5nZRseCuBumcBU8

Pedregosa, F., Varoquaux, G., Gramfort, A., Michel, V., Thirion, B., Grisel, O., ... & Duchesnay, É. (2011). Scikit-learn: Machine learning in Python. the Journal of machine Learning research, 12, 2825-2830. http://www.jmlr.org/papers/volume12/pedregosa11a/pedregosa11a.pdf?source=post_page





THANK YOU !!

The End